Universidade Estadual de Campinas

Centro Nacional de Processamento de Alto Desempenho
São Paulo

Apostila de Treinamento:

Introdução ao MPI

Revisão: 2012

Conteúdo

1-Computação Paralela

1.1– Processamento Serial

- Tradicionalmente os programas são escritos para processamento serial:

    - Execução em um computador com única CPU;
    - Os problemas são divididos em uma série de instruções;
    - Cada instrução é executada uma após a outra;
    - Somente uma instrução é executada por vez em qualquer momento do tempo de execução.

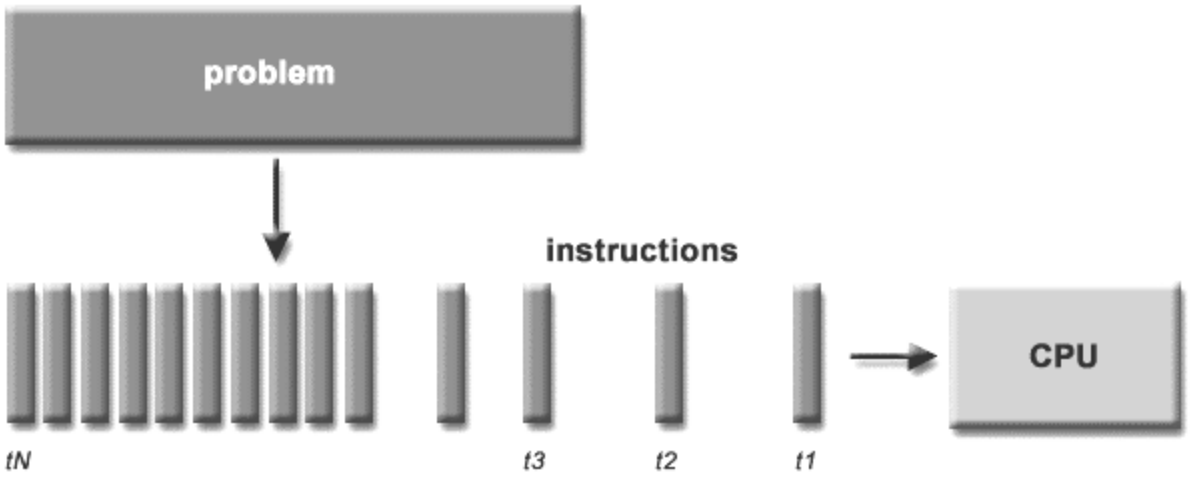

1.2 – Processamento Paralelo

- O processamento paralelo, de uma maneira simples, é o uso simultâneo de diversos recursos computacionais para resolver um problema:

    - Execução utilizando diversas CPUs;
    - Os problemas são divididos em diversos "pedaços", que podem ser resolvidos concorrentemente;
    - Cada "pedaço", por sua vez, é dividido em uma série de instruções;
    - As instruções de cada "pedaço" serão executadas simultaneamente em diferentes CPUs.

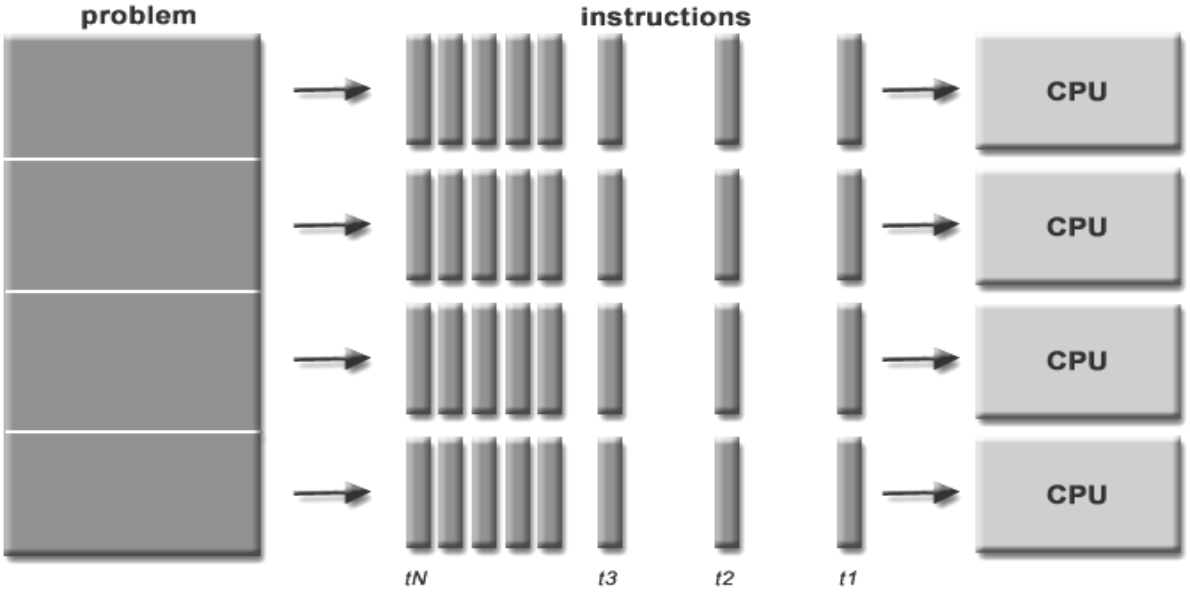

1.3 – Recursos e Necessidades

- Os recursos computacionais para o processamento paralelo podem ser:

    - Um unidade de processamento (um nó) com várias CPUs (cores);
    - Um número ilimitado de computadores conectados por uma rede;
    - Uma combinação de ambos os itens acima.

- Os problemas computacionais devem possuir características que possibilitem:

    - Serem divididos em "pedaços", e que possam ser solucionados, de uma maneira **concorrente, simultânea**;
    - Executar diversas instruções de programa a qualquer momento no tempo de execução;
    - Serem solucionados em um menor espaço de tempo que o equivalente serial;

- A computação paralela vem sendo considerada como "o objetivo final em computação", vem sendo motivada pelas simulações numéricas de sistemas complexos e devido aos grandes desafios computacionais científicos:

    - Previsão do tempo;
    - Comportamento do clima no mundo;
    - Reações químicas e nucleares;
    - Estudo do genoma humano;
    - Desenvolvimento de equipamentos mecânicos: Simulação de aviões, carros, máquinas;
    - Desenvolvimento de circuitos eletrônicos: Tecnologia de semicondutores, microchips;
    - Etc.

- As aplicações comerciais, também intensificaram num igual e forte esforço, no desenvolvimento de computadores cada vez mais rápidos. As aplicações necessitam de processamento de imensas bases de dados de várias maneiras sofisticadas:

    - Banco de Dados com processamento paralelo (Oracle, DB2) ;
    - "Data Mining", mineração de dados;
    - Exploração de petróleo;
    - Mecanismos de busca na web;
    - Diagnósticos médicos assistidos por computador;
    - Realidade virtual;
    - Tecnologia em multimídia;

1.4 – Por que usar computação paralela?

- Principais razões:

  - Reduzir o tempo total de execução;
  - Resolver grandes problemas;
  - **Utilizar concorrência (vários processamentos ao mesmo tempo)**.

- Outras razões:

  - Tirar vantagens dos recursos disponíveis na rede (Internet), disponibilizados por grandes centros de processamento de dados (Computação em GRID);
  - Baixar os custos de processamento, utilizando estações de trabalho, processadores comuns no mercado, ao invés de se utilizar "supercomputadores";
  - Recursos de memória – Um simples computador possui memória finita ao invés de se utilizar os recursos de memória de diversos computadores;
  - Limitação do processamento serial, baseados nos limites físicos e práticos da construção de máquinas seriais mais rápidas:
    - Velocidade de transmissão das informações:
      - Limite absoluto: Velocidade da luz – 30cm/nanosegundos.
      - Limite no cobre – 9cm/nanosegundos.
    - Limites de miniaturização: Nível atômico ou molecular
    - Limites econômicos;
  - O paralelismo é uma necessidade e, é o futuro da computação.

1.5 – Quem usa e para que usa computação paralela

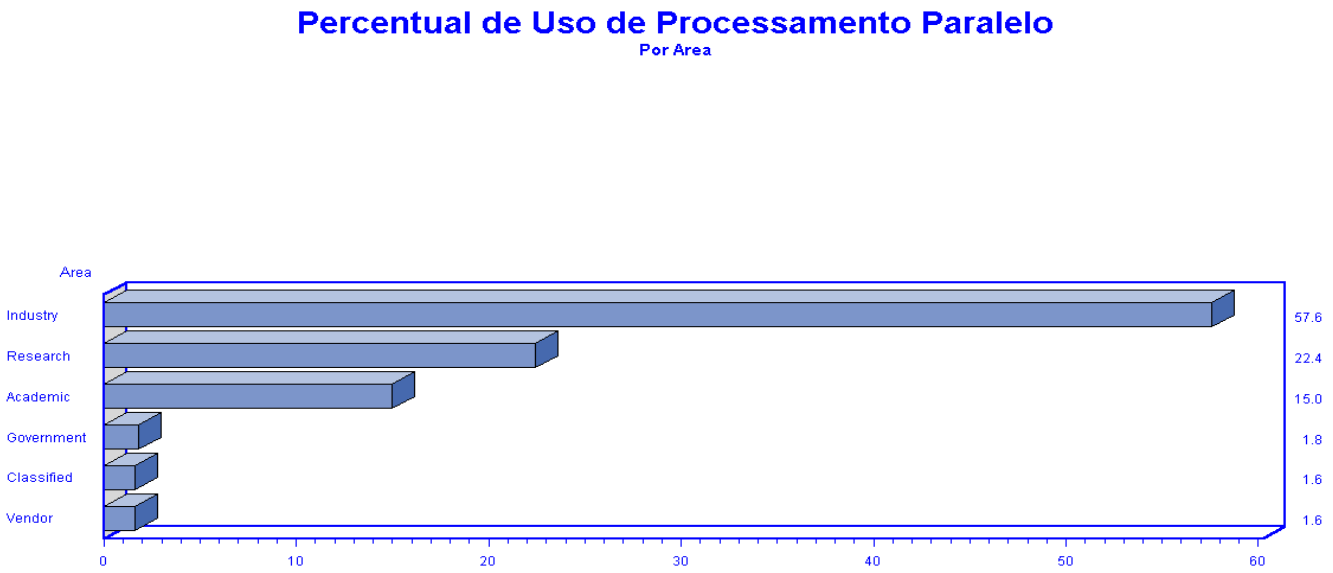

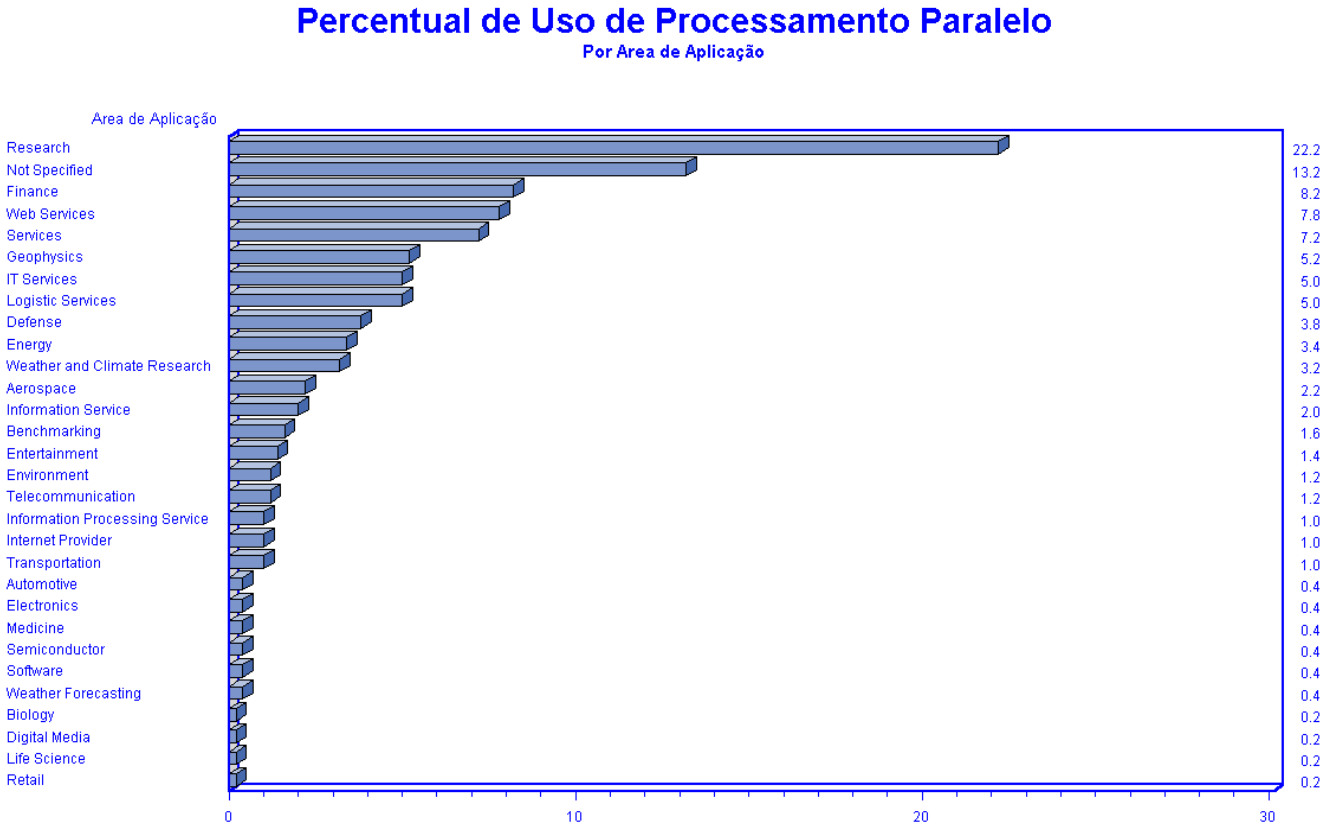

Fonte: top500.org 11/2011

1.6 – Conceitos e Terminologia

- Existem diversas maneiras de se classificar computadores paralelos. Uma das mais utilizadas, desde 1966, é a classificação de **Flynn**.

- Essa classificação distingue arquiteturas de computadores com múltiplos processadores, combinando duas dimensões independentes: **Instrução** e **Dados.** Cada dimensão só pode ter dois estados: **Simples** ou **Múltiplos.**

- Existem quatro possibilidades de classificação:

S I S D **Single Instruction, Single Data**	**S I M D** **Single Instruction, Multiple Data**
M I S D **Multiple Instruction, Single Data**	**M I M D** **Multiple Instruction, Multiple Data**

- **SISD – S**ingle **I**nstruction**, S**ingle **D**ata

  - Computador serial;
  - Somente uma instrução por vez;
  - Somente um fluxo de dado é utilizado por ciclos de CPU;
  - Exemplos: A maioria dos PCs;

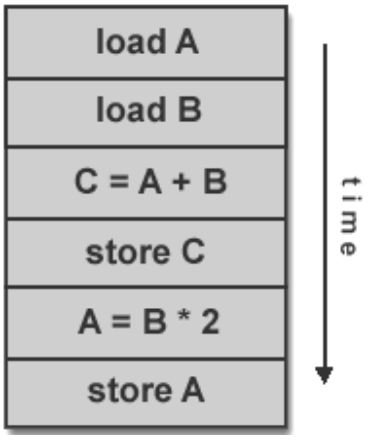

- **SIMD – S**ingle **I**nstruction, **M**ultiple **D**ata

  - Tipo de computador paralelo;
  - Todas as CPUs executam a mesma instrução;
  - Cada CPU opera em um conjunto de dados diferentes;
  - Arquitetura idealizada para aplicações que necessitam processar vetores: Tratamento de imagens;
  - Exemplos: IBM 9000, Cray C90, NEC SX-3.

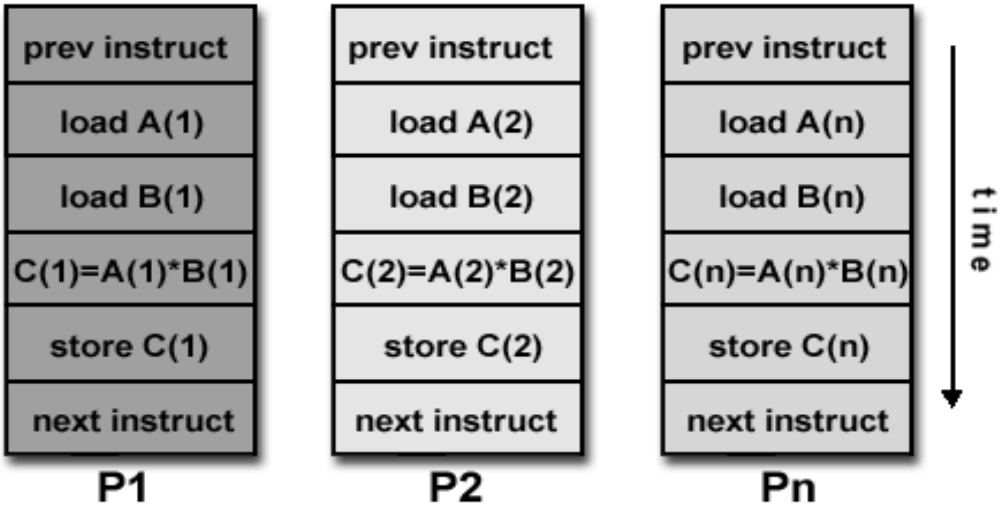

- **MISD – M**ultiple **I**nstruction, **S**ingle **D**ata

  - Um único conjunto de dados é processado por múltiplas CPUs;
  - Não existe computador comercial com essa classificação;
  - Possíveis aplicações:
    - Múltiplos filtros de freqüência, analisando um mesmo sinal;
    - Múltiplos algoritmos de criptografia analisando uma única mensagem;

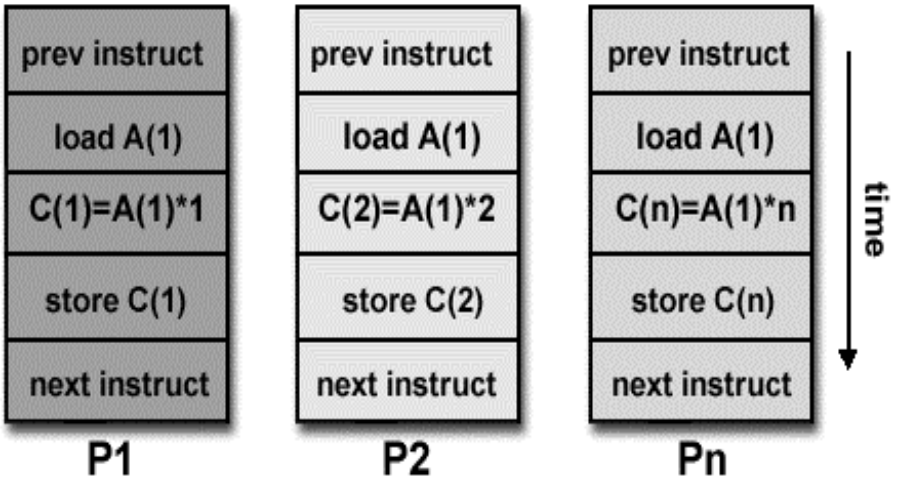

- **MIMD – M**ultiple **I**nstruction, **M**ultiple **D**ata

  - Computador paralelo mais comum;
  - Cada CPU pode executar um conjunto de instruções diferentes;
  - Cada CPU pode processar um conjunto de dados diferentes;
  - A execução pode ser síncrona ou assíncrona;
  - Exemplos: A maioria dos supercomputadores atuais, redes de computadores (“grid”), clusters

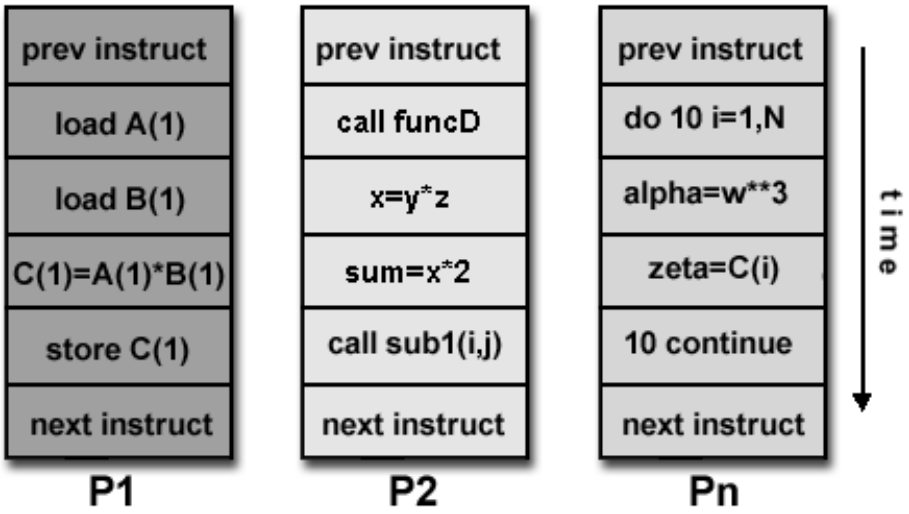

- **Task - Tarefa**

  Seção lógica de um "trabalho" computacional. Tipicamente, a **Tarefa** representa um programa com um conjunto de instruções que são executadas pelo processador.

- **Parallel Task – Tarefa Paralela**

  Seção lógica de um "trabalho" computacional, que pode ser executado, de maneira confiável, por múltiplos processadores.

- **Serial Execution – Execução Serial**

  Execução de um programa seqüencialmente, comando após comando. Normalmente, é a situação de máquinas com um único processador.

- **Parallel Execution – Execução Paralela**

  Execução de um programa que possui mais de uma seção lógica (tarefa) e que podem ser executadas ao mesmo tempo.

- **Shared Memory – Memória Compartilhada**

  Descreve uma arquitetura de computador aonde todos os processadores possuem acesso direto ("Data Bus") à uma mesma memória física.

- **Distributed Memory – Memória Distribuída**

  Descreve uma arquitetura de computador aonde cada processador utiliza sua própria memória física, mas todos são conectados entre si por meio de uma interface de comunicação, um "switch" (Ex.: InfiniBand), ou uma rede.

- **Synchronization – Sincronização**

  É a coordenação das comunicações entre as tarefas paralelas em tempo real. É utilizado em aplicações cujas tarefas paralelas não podem prosseguir enquanto as outras tarefas atinjam o mesmo ponto lógico da execução. Sincronização, usualmente, envolve tempo de espera por pelo menos uma tarefa, o que pode causar um aumento no tempo total de execução da aplicação.

- **Granularity - Granularidade**

  Em computação paralela, granularidade é uma medida da razão entre computação e comunicação.

  Coarse (Grosso) – Grande número de trabalho computacional entre eventos de comunicação;
  Fine (Fino) – Pequeno número de trabalho computacional entre eventos de comunicação;

- **Observed Speedup – Aumento da Velocidade de Processamento**

$$\frac{\text{Tempo total da execução serial}}{\text{Tempo total da execução paralela}}$$

- **Parallel Overhead**

  Tempo gasto e necessário para coordenar as tarefas paralelas. Os fatores de coordenação podem ser:

  Início de processos paralelos
  Sincronizações durante a execução
  Comunicação de dados entre os processos
  Compiladores paralelos, bibliotecas, ferramentas, sistema operacional, etc.
  Finalização de processos paralelos

- **Massively Parallel**

  Hardware que constitui o sistema paralelo, possuindo diversos processadores e permitindo o aumento desse sistema (Quantidade atual de processadores nos grandes centros de supercomputação, gira em torno de 6 dígitos).

- **Scalability – Escalabilidade**

  Refere-se ao sistema paralelo que demonstra a habilidade de aumentar a velocidade de processamento com a adição de novos processadores.

1.7 – Arquitetura de Memória

Shared Memory – Memória Compartilhada

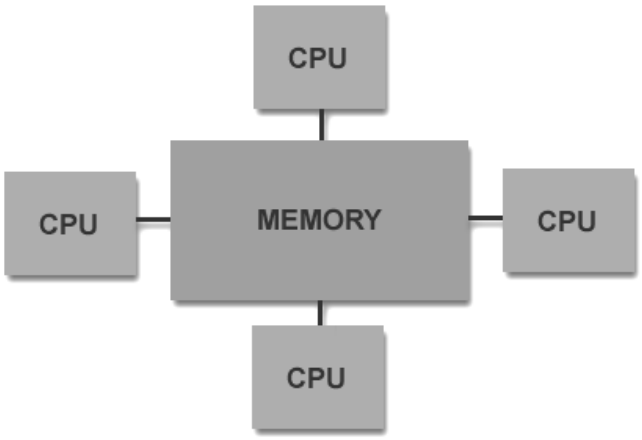

- Computadores de memória compartilhada variam muito de configuração, mas no geral possuem em comum a habilidade de todos os processadores acessarem toda a memória como um espaço de endereçamento comum ou global;

- Múltiplos processadores podem operar de forma independente, mas compartilham os mesmos recursos de memória;

- Mudanças num endereço de memória por um processador será visível por todos os outros processadores;

- As máquinas com memória compartilhada podem ser divididas em duas classes baseadas no número de acessos e no intervalo de acesso à memória: ***UMA*** e ***NUMA***.

Uniform Memory Access (UMA)

- Máquinas SMP (Symmetric Multiprocessor);
- Processadores idênticos;
- O Número de acessos à memória é dividido igualmente por entre todos os processadores;
- Também chamadas de CC-UMA – Cache Coherent UMA – Se um processador altera um endereço de memória, todos os processadores serão "avisados" da atualização. É uma implementação à nível de hardware.

Non-Uniform Memory Access (NUMA)

- Ambiente paralelo que possui a ligação física entre duas ou mais máquinas SMPs;
- Cada máquina SMP tem acesso direto à memória das outras máquinas SMPs;
- O número de acessos a memória não é igualmente dividido entre todos os processadores do ambiente;
- O acesso a memória de outra SMP é mais lento;
- Se for mantida a coerência de cachê, o ambiente é chamado de CC-NUMA

- **Vantagens:**
  - O Endereçamento global permite uma programação mais simples e um processamento mais rápido;
  - O compartilhamento de dados entre tarefas é rápido e uniforme devido a proximidade entre memória e CPUs.

- **Desvantagens:**
  - Escalabilidade. A adição de mais CPUs pode aumentar geometricamente o tráfico de dados na memória compartilhada com as CPUs e com o sistema de gerenciamento da memória cache;
  - Alto custo na fabricação de máquinas SMPs com muitos processadores;

Distributed Memory – Memória Distribuída

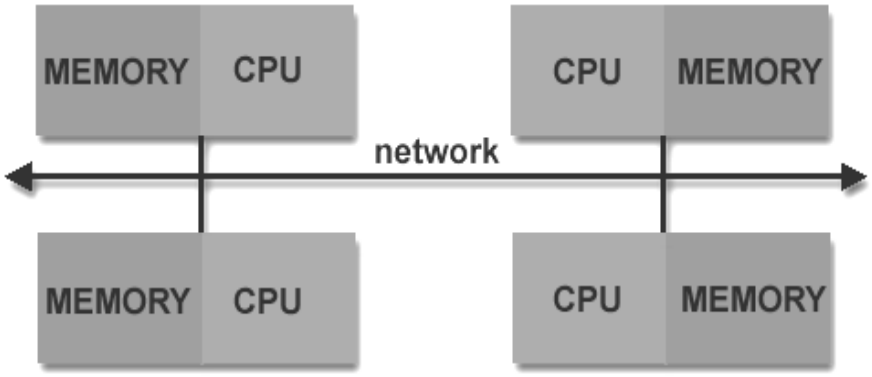

- Sistemas de memória distribuída necessitam de uma rede de comunicação que conecta os processadores entre si;

- Cada processador possui sua própria memória local;

- O endereçamento de memória de um processador não endereça a memória de outro processador, ou seja, não existe o conceito de endereçamento global;

- Cada processador opera independentemente. Mudanças em um endereço de memória de um processador, não são informadas para os outros processadores. Não existe o conceito de coerência de cache;

- Quando o processador necessita de um dado de outro processador, será a tarefa paralela em execução do programador, que explicitamente definirá como será a comunicação. A sincronização de tarefas é uma responsabilidade do programador;

- **Vantagens:**

    - Escalabilidade. A memória do sistema aumenta com o aumento do número de processadores;
    - Cada processador tem acesso rápido a sua memória, sem a interferência e o custo em se manter um sistema de coerência de cache;

- **Desvantagens:**

    - O Programador é responsável por todos os detalhes associados a comunicação entre os processadores;

Híbridos

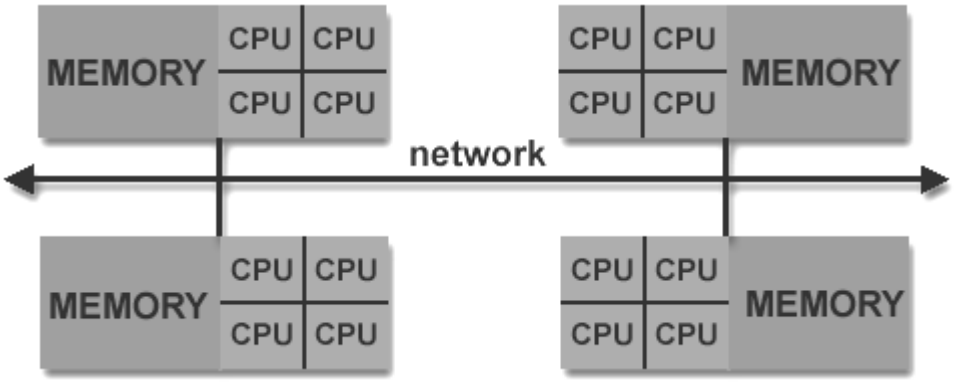

- Atualmente os computadores mais rápidos no mundo utilizam ambas as arquiteturas de memória;
- Os componentes de memória compartilhada são usualmente máquinas SMPs com coerência de cache;
- Os componentes de memória distribuída são máquinas SMPs conectadas em rede;

Arquitetura	CC-UMA	CC-NUMA	Distributed
Exemplos	SMPs DEC/Compaq SGI Challenge IBM POWER3	SGI Altix HP Exemplar DEC/Compaq IBM POWER4 (MCM)	Cray T3E Maspar IBM SP2
Comunicação	MPI Threads OpenMP shmem	MPI Threads OpenMP shmem	MPI
Escalabilidade	Dezenas de processadores	Centenas de processadores	Milhares de processadores
Disponibilidade de Software	Milhares	milhares	centenas

1.8 – Modelos de Programação Paralela

Memória Compartilhada

- As tarefas compartilham o mesmo espaço de endereçamento. O acesso é feito em modo assíncrono;
- A grande vantagem desse modelo, é que a comunicação entre as tarefas é feita de maneira implícita, não havendo necessidade de controlar essa comunicação, tornando a programação mais fácil;
- A implementação desse modelo é feita pelos compiladores nativos do ambiente.

Threads

- Um único processo pode possuir múltiplos e concorrentes sub processos, ou melhor, "processos leves", que são sub tarefas independentes;
- Todos os "processos leves" compartilham o mesmo espaço de memória do processo principal;
- Não existe proteção de memória entre threads.
- Uma analogia simples que pode ser utilizada para entender threads, seria a de um programa com várias sub-rotinas;

  1 - O programa principal **a.out** inicia a execução, carrega e adquire todos os recursos necessários do sistema para a execução;

  2 – O programa **a.out** efetua algum trabalho serial e então gera um número de tarefas (threads), que podem ser agendados e executados simultaneamente pelo sistema operacional;

  3 – Cada thread possui seus próprios dados, mas podem compartilhar os recursos do programa principal, **a.out**, evitando, assim, a replicação de recursos para cada thread;

  4 – Cada thread se beneficia também do acesso ao endereçamento de memória do programa **a.out**;

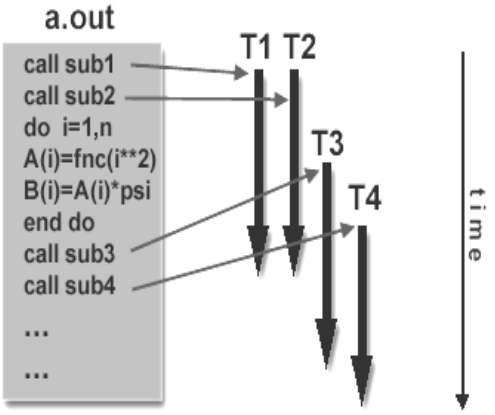

  5 – O trabalho de uma thread pode ser melhor descrito como uma sub rotina do programa principal. Qualquer thread pode executar qualquer sub rotina, ao mesmo tempo, que outras threads;

  6 – As threads se comunicam entre si através da memória principal (atualizando endereços). Isto requer sincronização nos acessos para garantir que não existam outras threads tentando atualizar o mesmo endereço ao mesmo tempo;

- Threads são normalmente associados a arquiteturas de memória compartilhada;
- Implementações:
  - Posix Threads (Pthreads) – somente em C
  - OpenMP – C/C++ e Fortran

“Message Passing”

- Modelo normalmente associado a ambiente de memória distribuída;

- Múltiplas tarefas iniciadas e distribuídas pelos processadores do ambiente, utilizando o seu próprio endereçamento de memória;

- As tarefas compartilham dados através de comunicação de envio e recebimento de mensagens (“message-passing”);

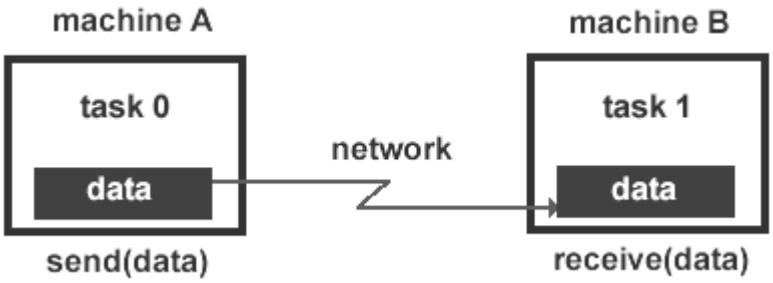

- O programador é responsável por determinar todo o paralelismo e a comunicação entre as tarefas;

- A transferência de dados, usualmente requer a cooperação de operações entre os processos. Ex.: Uma operação de envio de mensagem por um processo tem que “casar” com uma operação de recebimento de outro processo;

- Implementações: PVM, Linda, MPI

“Data Parallel” – Paralelismo de Dados

- O trabalho paralelo é efetuado em um conjunto de dados;
- Os dados devem estar organizados na forma de vetores;
- Cada tarefa trabalha com partições diferentes da estrutura de dados;
- Cada tarefa efetua a mesma operação em sua partição da estrutura de dados;

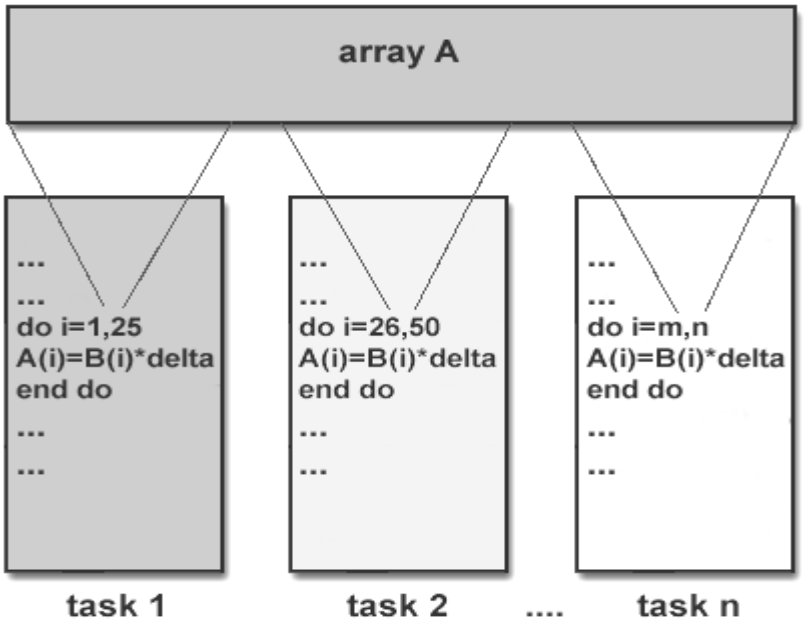

- Em Memória compartilhada – Todos as tarefas possuem acesso a estrutura de dados na memória global;
- Em Memória distribuída – Partições da estrutura de dados são distribuídas para a memória de cada tarefa em cada processador do ambiente;
- A programação baseada nesse modelo utiliza recursos de paralelismo de dados, que normalmente são sub rotinas de uma biblioteca “Data Parallel” ou diretivas (opções) de um compilador;
- Implementações:

  - Data Parallel Compilers: Fortran90/95, HPF - High Performance Fortran
  - Message Passing: MPI, LAM, MPICH

2 - Criação de um Programa Paralelo

2.1 - Decomposição do Programa

- Para se decompor um programa em pequenas tarefas que serão executadas em paralelo, é necessário se ter idéia da *decomposição funcional* e da *decomposição de domínio*.

Decomposição Funcional

- O **problema** é decomposto em **diferentes** tarefas, gerando diversos programas, que serão distribuídos por entre múltiplos processadores para execução simultânea;

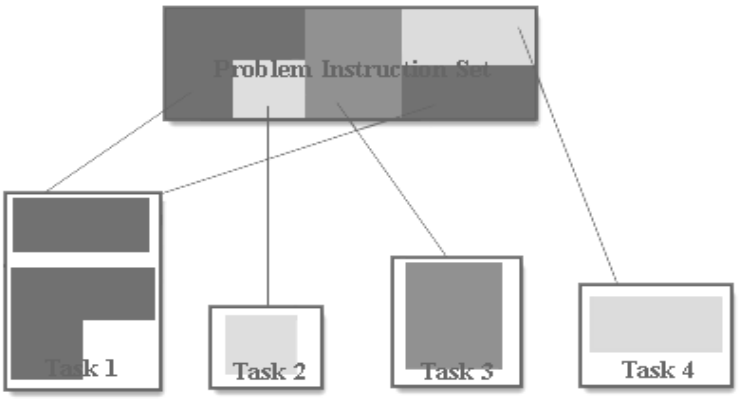

Decomposição de Domínio

- Os **dados** são decompostos em grupos, que serão distribuídos por entre múltiplos processadores que executarão, simultaneamente, um **mesmo** programa;

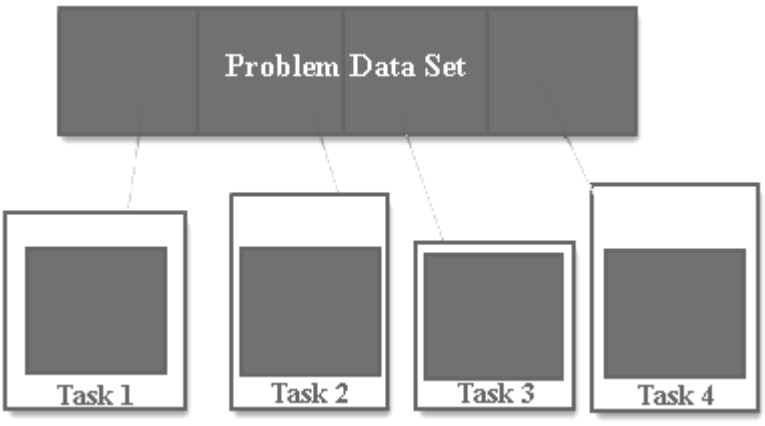

- Os métodos de comunicação para "Message-Passing" e para "Data Parallel", são exatamente os mesmos.

    - Comunicação Point to Point (Send-Receive);

    - Comunicação Coletiva: Broadcast, Scatter, Gather, Collective Computations (Reduction).

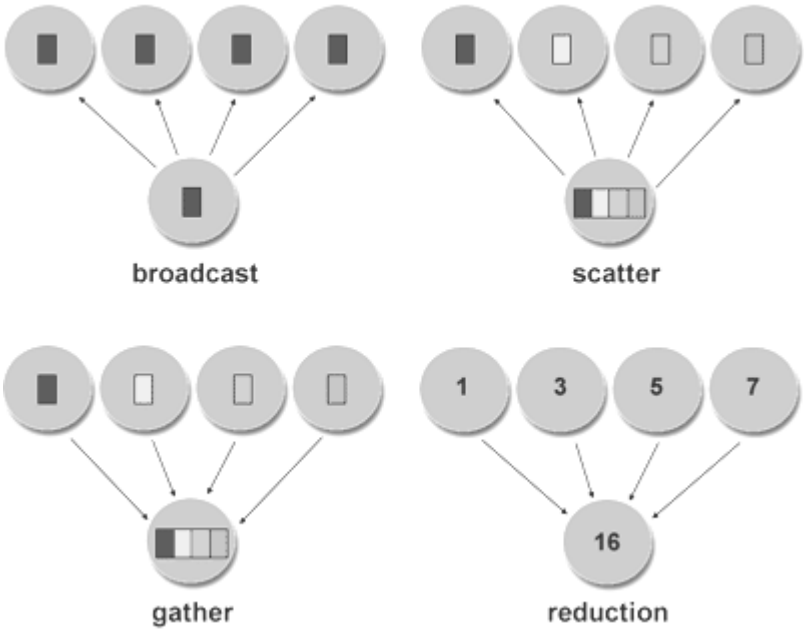

3 - Considerações de Performance

3.1 - Amdahl's Law

- A lei de Amdahl's determina o potencial de aumento de velocidade a partir da porcentagem de paralelismo, **por decomposição funcional**, de um programa (**f**):

  speedup = 1 / (1 - f)

- Num programa, no qual não ocorra paralelismo, **f=0**, logo, **speedup=1** (Não existe aumento na velocidade de processamento);

- Num programa, no qual ocorra paralelismo total, **f=1**, logo, **speedup é infinito** (Teoricamente).

- Se introduzirmos o número de processadores na porção paralela do processamento, a relação passará a ser modelada por:

speedup = 1 / [(P/N) + S]

P = Porcentagem paralela;
N = Número de processadores;
S = Porcentagem serial;

N	P = 0,50	P = 0,90	P = 0,99
10	1,82	5,26	9,17
100	1,98	9,17	50,25
1000	1,99	9,91	90,99
10000	1,99	9,91	99,02

3.2 - Balanceamento de Carga ("Load Balancing")

- A distribuição das tarefas por entre os processadores, deve ser de uma maneira que o tempo da execução paralela seja eficiente;

- Se as tarefas não forem distribuídas de maneira balanceada, é possível que ocorra a espera pelo término do processamento de uma única tarefa, para dar prosseguimento ao programa.

"Granularity"

- É a razão entre computação e comunicação:

- **Fine-Grain**

  - Tarefas executam um pequeno número de instruções entre ciclos de comunicação;
  - Facilita o balanceamento de carga;
  - Baixa computação, alta comunicação;
  - É possível que ocorra mais comunicação do que computação, diminuindo a performance.

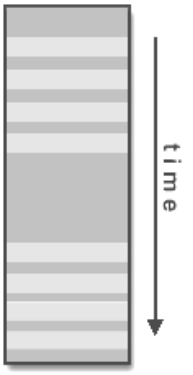

- **Coarse-Grain**

  - Tarefas executam um grande número de instruções entre cada ponto de sincronização;
  - Difícil de se obter um balanceamento de carga eficiente;
  - Alta computação, baixa comunicação;
  - Possibilita aumentar a performance.

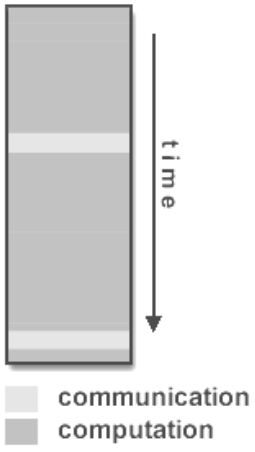

4 – Introdução a "Message-Passing"

4.1 - O Modelo "Message-Passing"

- O modelo "Massage-Passing" é um dos vários modelos computacionais para conceituação de operações de programa. O modelo "Message-Passing" é definido como:

    - Conjunto de processos que possuem acesso à memória local;

    - Comunicação dos processos baseados no envio e recebimento de mensagens;

    - A transferência de dados entre processos requer operações de cooperação entre cada processo (uma operação de envio deve "casar" com uma operação de recebimento).

4.2 – Bibliotecas de "Message-Passing"

- A implementação de uma biblioteca de "Message-Passing", baseia-se na construção de rotinas de comunicação entre processos.

Domínio público - PICL, PVM, PARMACS, P4, MPICH, LAM, UNIFY,etc**;**

Proprietárias – MPL(IBM), NX(NEC), CMMD(CM), MPI(IBM, CRAY, SGI, Intel), etc;

- Existem componentes comuns a todas as bibliotecas de "Message-Passing", que incluem:

    - Rotinas de gerência de processos: iniciar, finalizar, determinar o número de processos, identificar processos, etc;

    - Rotinas de comunicação "Point-to-Point": Enviar e receber mensagens entre dois processos;

    - Rotinas de comunicação Coletiva: "broadcast", “scatter”, “gatter”, “reduce” e sincronizar processos.

4.3 -Terminologia de Comunicação

- **Buffering**

  Cópia temporária de mensagens entre endereços de memória efetuada pelo sistema MPI, como parte de seu protocolo de transmissão. A cópia ocorre entre o **buffer da aplicação** (variáveis do programa) e o **buffer do sistema** (definido pela biblioteca MPI);

  Em um processamento teórico, toda operação de envio deve estar perfeitamente sincronizada e casada com uma operação de recebimento. Isto é raro! Portanto, toda implementação de MPI deve possibilitar o armazenamento das mensagens no caso dos processos não estarem sincronizados;

  Considere os dois casos abaixo:

  - Uma operação de envio ocorre 5 segundos antes da operação de recebimento estar ativa. A onde estará a mensagem enquanto o recebimento estiver pendente?

  - Múltiplas operações de envio são feitas para o mesmo processo, que só pode aceitar uma mensagem por vez. O que acontece com as outras mensagens enviadas?

  A própria biblioteca MPI decide o que fazer com as mensagens nesses casos. Normalmente é reservada uma área de memória para armazenar os dados em trânsito – **buffer do sistema MPI (System Buffer)**.

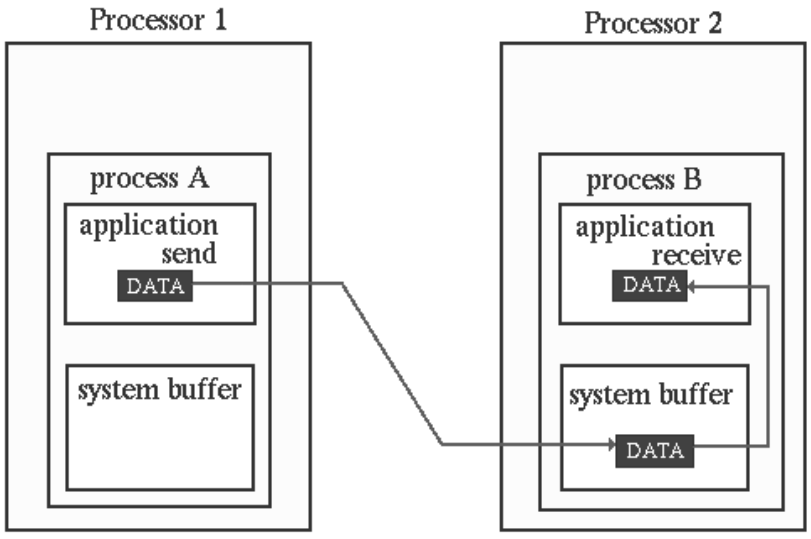

Path of a message buffered at the receiving process

  O espaço do System Buffer é:

  - Transparente para o programador e gerenciado pelo MPI;
  - Um recurso limitado e facilmente esgotado;
  - Não é bem documentado;
  - Pode existir no processo que envia, no que recebe e em ambos;
  - É um recurso que melhora a performance do programa, pois permite operações de envio e recebimento, assíncronos.

- **Blocking**

  Uma rotina de comunicação é **blocking**, quando a finalização da execução da rotina, depende de certos eventos, ou seja, espera por determinada ação, antes de liberar a continuação do processamento:

  - Uma rotina **blocking send** somente termina após o **buffer da aplicação** (variável), estiver seguro e liberado para uso. Seguro, significa que qualquer modificação no buffer, não irá afetar o dado transmitido para o processo que recebe. Seguro, não implica que o dado já tenha sido recebido;

  - Um **blocking send** pode ser síncrono, o que significa que existe uma comunicação ocorrendo com o processo que recebe, com confirmação da transmissão da mensagem pelo processo que recebe;

  - Um **blocking send** pode ser assíncrono, o que significa que o **system buffer** está sendo utilizado para armazenar uma mensagem para ser enviada;

  - Um **blocking receive** só retorna a execução após a mensagem ter chegado, e estar pronta para ser utilizada pelo programa.

- **Non-blocking**

  Uma rotina de comunicação é **non-blocking**, quando a finalização da execução da rotina, não depende de certos eventos, ou seja, não há espera por uma ação, o processo continua sendo executado normalmente;

  - As operações **non-blocking** solicitam à biblioteca MPI que execute a operação quando for possível. O programador não tem idéia de quando isso irá ocorrer;

  - Não é seguro modificar o valor do buffer de aplicação, até que se saiba que a operação **non_blocking** tenha sido executada pela biblioteca MPI;

  - As operações **non-blocking** são utilizadas para evitar problemas de comunicação **("deadlock")** e melhorar a performance.

- **Síncrono**

  Comunicação na qual o processo que envia a mensagem, não retorna a execução normal, enquanto não haja um sinal do recebimento da mensagem pelo destinatário;

- **Assíncrono**

  Comunicação na qual o processo que envia a mensagem, não espera que haja um sinal de recebimento da mensagem pelo destinatário

- **Comunicação "Point-to-Point"**

  Os componentes básicos de qualquer biblioteca de "Message-Passing" são as rotinas de comunicação "Point-to-Point" (transferência de dados entre **dois** processos).

Bloking	**Send**	Finaliza, quando o "buffer" de envio está pronto para ser reutilizado;
	Receive	Finaliza, quando o "buffer" de recebimento está pronto para ser reutilizado;
Nonblocking		Retorna imediatamente, após envio ou recebimento de uma mensagem.

- **Comunicação Coletiva**

  As rotinas de comunicação coletivas são voltadas para coordenar **grupos** de processos.

  Existem, basicamente, três tipos de rotinas de comunicação coletiva:

  Sincronização

  Envio de dados: Broadcast, Scatter/Gather, All to All

  Computação Coletiva: Min, Max, Add, Multiply, etc;

- **"Overhead"**

  Existem duas fontes de "overhead" em bibliotecas de "message-passing":

"System Overhead"	É o trabalho efetuado pelo sistema para transferir um dado para seu processo de destino; Ex.: Cópia de dados do "buffer" para a rede.
"Syncronization Overhead"	É o tempo gasto na espera de que um evento ocorra em um outro processo; Ex.: Espera, pelo processo origem, do sinal de OK pelo processo destino.

5 – Introdução ao MPI

5.1 - O que é MPI ?

- **M**essage **P**assing **I**nterface
- Uma biblioteca de "Massage-Passing", desenvolvida para ser padrão, inicialmente, em ambientes de memória distribuída, em "Message-Passing" e em computação paralela.
- "Message-Passing" portável para qualquer arquitetura, tem aproximadamente 125 funções para programação e ferramentas para se analisar a performance.
- Utilizado por programas codificados em C e FORTRAN.
- A plataforma para uso do MPI, são os ambientes com máquinas paralelas massivas.
- Todo paralelismo é **explícito:** o programador é responsável em identificar o paralelismo e implementar um algoritmo utilizando construções com o MPI.

5.2 – Histórico

- **Final da década de 80**

  Memória distribuída, o desenvolvimento da computação paralela, ferramentas para desenvolver programas em ambientes paralelos, problemas com portabilidade, performance, funcionalidade e preço, determinaram a necessidade de se desenvolver um padrão.

- **Abril de 1992**

  "Workshop" de padrões de "Message-Passing" em ambientes de memória distribuída (Centro de Pesquisa em Computação Paralela, Williamsburg, Virginia); Criado um grupo de trabalho para dar continuidade ao processo de padronização.

- **Novembro de 1992**

  Reunião em Minneapolis do grupo de trabalho e apresentação de um primeiro esboço de interface "Message-Passing" (**MPI1**). Criação de um **MPI Forum,** que consiste eventualmente de aproximadamente 175 pessoas de 40 organizações, incluindo fabricantes de computadores, empresas de softwares, universidades e cientistas de aplicação.

- **Maio de 1994**

  Disponibilização como domínio público, da versão padrão do MPI, atualmente, o padrão **MPI-2**: http://www.mcs.anl.gov/research/projects/mpich2/

- **Dezembro de 1995**

  Conferência de Supercomputação 95 - Reunião para discussão do **MPI-2** e suas extensões.

5.3 – Instalação Básica do MPICH2

- **download**

  wget http://www.mcs.anl.gov/research/projects/mpich2/downloads/tarballs/1.3.2p1/mpich2-1.3.2p1.tar.gz

- **desempacotar**

  tar xfz mpich2.tar.gz ou gunzip -c mpich2.tar.gz | tar xf -

- **configurar a instalação**

  Opção para definir o "Process Manager" - Administrador de Processos (**--with-pm=)**:

  hydra Opção "default", utiliza os "daemons" nativos já instalados no ambiente: ssh, slurm, pbs;

  mpd Opção tradicional do MPICH2 que instala um "daemon" próprio de controle de processos;

  smpd Única opção disponível para o ambiente Windows;

  gforker Opção de controle de processos utilizado em ambientes homogeneos de processadores e ambientes de memória compartilhada.

  Opção para definir o método de comunicação (**--with-device=**):

  ch3:nemesis Método "default", de alta performance. Utilizado em ambiente híbridos. Usa memória compartilhada entre processos no mesmo "nó" e rede TCP/IP nos processos entre os "nós";

  ch3:sock Método para ambientes apenas com memória distribuída, utiliza a rede TCP/IP para comunicação entre todos os processos.

  Exemplo do comando "configure" e outras opções, com os compiladores da GNU:

```
./configure  --prefix=/usr/local/mpich2
             --with-pm=gforker
             --with-device=ch3:nemesis
             --enable-fc
             --enable-cxx
             --disable-check-compiler-flags
             --enable-fast=O3
             CC=gcc
             CXX=g++
             FC=gfortran
             F77=gfortran
             FCFLAGS=-m64
             FFLAGS=-m64
             CFLAGS=-m64
             CXXFLAGS=-m64
```

- **instalação**

  make
  make install

5.4 – Conceitos e Definições

- **Rank**

  Todo processo tem uma única identificação, atribuída pelo sistema quando o processo é iniciado. Essa identificação é continua e começa no zero até n-1 processos.

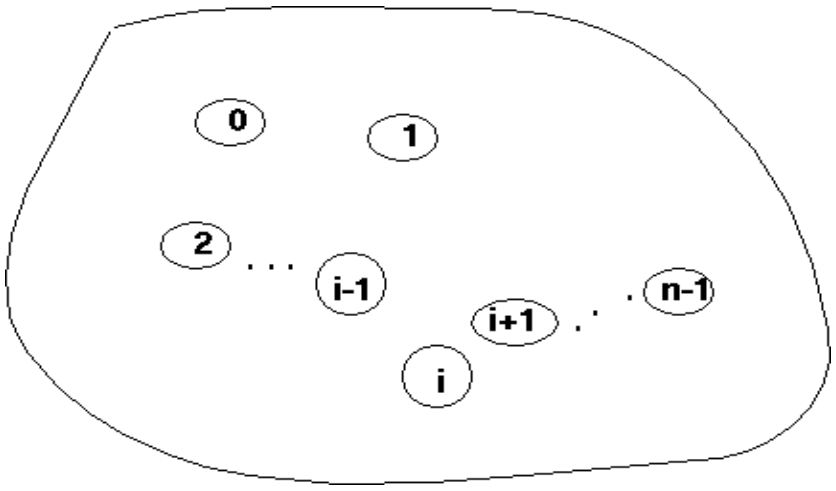

- **Group**

  Grupo é um conjunto ordenado de N processos. Todo e qualquer grupo é associado a um "communicator" e, inicialmente, todos os processos são menbros de um grupo com um "communicator" já pré-estabelecido (**MPI_COMM_WORLD**).

- **Communicator**

  O "communicator" define uma coleção de processos (grupo), que poderão se comunicar entre si (contexto). O MPI utiliza essa combinação de grupo e contexto para garantir uma comunicação segura e evitar problemas no envio de mensagens entre os processos.

  É possível que uma aplicação de usuário utilize uma biblioteca de rotinas, que por sua vez, utilize "message-passing". Essa subrotina da biblioteca, pode por sua vez, usar uma mensagem idêntica a mensagem da aplicação do usuário.

  As rotinas do MPI exigem que seja especificado um "communicator" como argumento. MPI_COMM_WORLD é o comunicador pré-definido que inclui, inicialmente, todos os processos definidos pelo usuário, numa aplicação MPI.

Ação Desejada

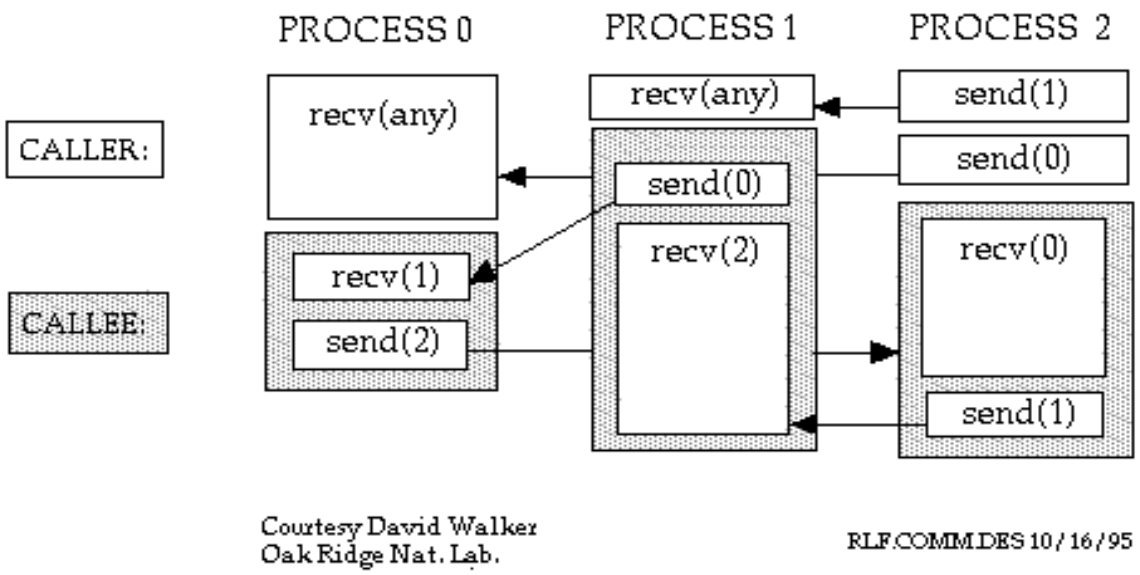

Courtesy David Walker
Oak Ridge Nat. Lab.

RLF.COMMDES 10/16/95

Possível ação indesejada

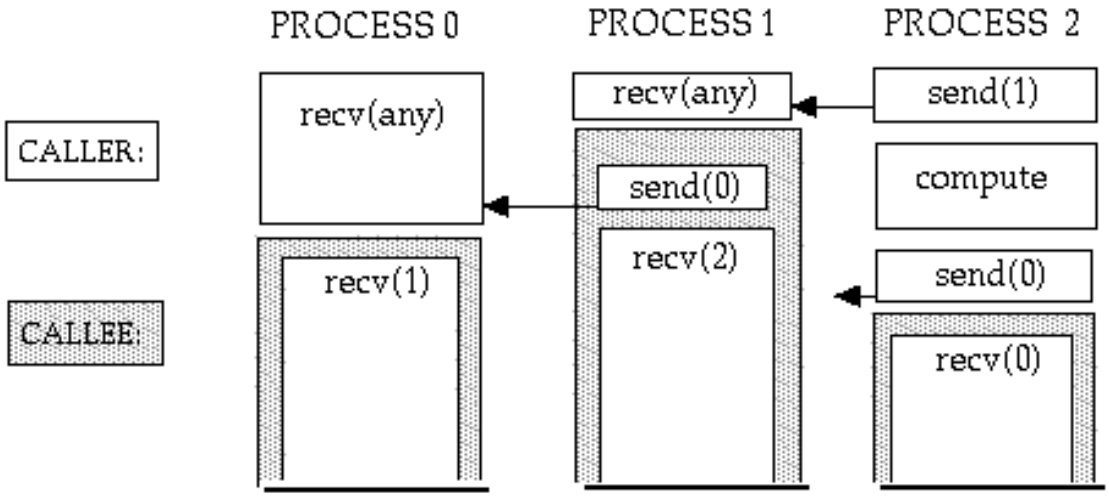

Courtesy David Walker
Oak Ridge Nat. Lab.

RLF.COMMINC 10/16/95

- **Aplication Buffer**

  É um endereço normal de memória (Ex: endereço de uma variável) aonde se armazena um dado que o processo necessita enviar ou receber.

- **System Buffer**

  É um endereço de memória reservado pelo sistema para armazenar mensagens. Normalmente, em comunicação assíncrona, numa operação de **send/receive**, o dado no "aplication buffer" pode necessitar ser copiado **de/para** o "system buffer" (**"Send Buffer" e "Receive Buffer"**).

- **Blocking Comunication**

  Numa rotina de comunicação **bloking**, a finalização da chamada depende de certos eventos.

  Ex: **Numa rotina de envio**, o dado tem que ter sido enviado com sucesso, ou, ter sido salvo no "system buffer", indicando que o endereço do "aplication buffer" pode ser reutilizado.

  Numa rotina de recebimento, o dado tem que ser armazenado no "system buffer", indicando que o dado pode ser utilizado.

- **Non-Blocking Communication**

  Uma rotina de comunicação é dita **"Non-blocking"** , se a chamada retorna sem esperar qualquer evento que indique o fim ou o sucesso da rotina.

  Ex: Não espera pela cópia de mensagens do "aplication buffer" para o "system buffer", ou qualquer indicação do recebimento de uma mensagem. É da responsabilidade do programador, a certeza de que o "aplication buffer" esteja disponível para ser reutilizado.

- **Standard Send**

  Implementação padrão do MPI de envio de mensagens, usada para transmitir dados de um processo para outro.

- **Synchronous Send**

  Operação sincronizada entre o processo que envia e o processo que recebe. O processo que envia, bloqueia a execução do programa até que ocorra uma operação de "receive" no processo destino.

- **Buffered Send**

  Operação de envio na qual se utiliza um novo "buffer" criado e adaptado ao tamanho dos dados que serão enviados. Isso pode ser necessário para evitar o processo de “buffering”, devido ao espaço padrão do "System Buffer".

- **Ready Send**

  Tipo de "send" que pode ser usado se o programador tiver certeza de que exista um "receive" correspondente, já ativo.

- **Standard Receive**

  Operação básica de recebimento de mensagens usado para aceitar os dados enviados por qualquer outro processo. Pode ser "blocking" e "non-blocking".

- **Return Code**

  Valor inteiro retornado pelo sistema para indicar a finalização da sub-rotina.

5.5 - Compilação

A compilação de uma aplicação que utiliza rotinas MPI, depende da implementação **MPI** existente no ambiente.

Ambiente IBM/AIX com "Parallel Enviroment" instalado

Fortran77

mpxlf <fonte.f> -o <executável>

Fortran90

mpxlf90 <fonte.f90> -o <executável>

C Standard

mpcc <fonte.c> -o <executável>

C++

mpCC <fonte.cxx> -o <executável>

Ambiente LINUX com processador e compiladores da INTEL e biblioteca MPI proprietária

Fortran77 ou Fortran90

ifort <fonte.f ou .f90> -o <executável> -lmpi

C Standard

icc <fonte.c> -o <executável> -lmpi

C++

icpc <fonte.cxx> -o <executável> -lmpi

Qualquer ambiente e compiladores, com biblioteca MPICH2

Fortran77

mpif77 <fonte.f> -o <executável>

Fortran90

mpif90 <fonte.f90> -o <executável>

C Standard

mpicc <fonte.c> -o <executável>

C++

mpicxx <fonte.cxx> -o <executável>

OBS: É possível utilizar todas as opções de compilação dos compiladores C e FORTRAN.

5.6 – Execução

A execução de uma aplicação que utiliza rotinas MPI, depende da implementação **MPI** existente no ambiente.

Ambiente IBM/AIX com "Parallel Enviroment" instalado

A execução de um programa, com rotinas **MPI,** no ambiente IBM/AIX, é feita através de uma interface de operação, instalada através do "Parallel Enviroment", e que configura o ambiente paralelo - POE, "***P**arallel **O**peration **E**nvironment".*

poe *executável* **-procs** *número de processos* **-hostfile** *arquivo de máquinas*

ou

export MP_PROCS=*número de processos*
export MP_HOSTFILE=*arquivo de máquinas*

poe *executável*

Ambiente LINUX com processador e compiladores da INTEL e biblioteca MPI proprietária

ulimit –v unlimited

mpirun -np *número de processos ./executável*

Qualquer ambiente e compiladores, com biblioteca MPICH2

mpiexec *executável* **-np** *número de processos* **-f** *arquivo de máquinas*

6 – Implementação Básica de um Programa com MPI

Para um grande número de aplicações, um conjunto de apenas **6 subrotinas MPI** serão suficientes para desenvolver uma aplicação com MPI e executar em paralelo. Em C, os nomes das rotinas e parâmetros são "case sensitive"; em Fortran, "case insensitive".

6.1 - Arquivo "headers"

Necessário para todos os programas e/ou subrotinas que efetuam chamadas para a biblioteca MPI. Normalmente é colocado no início do programa. Possui as definições básicas dos parâmetros das subrotinas e tipos de dados MPI.

C	**#include "mpi.h"**
FORTRAN	**include "mpif.h"**

C

```
#include "mpi.h"
#include <stdio.h>

int main( argc, argv )
int argc;
char **argv;
{
   MPI_Init( &argc, &argv );
   printf( "Hello world\n" );
   MPI_Finalize();
   return 0;
}
```

Fortran

```
program mpisimple
      implicit none
      integer ierr
      include 'mpif.h'
      CALL MPI_INIT(ierr)
c     print message to screen
      write(6,*) 'Hello World!'
      CALL MPI_FINALIZE(ierr)
end
```

6.2 - Iniciar um processo MPI

MPI_INIT

- Primeira rotina MPI a ser utilizada;
- Define e inicializa o ambiente necessário para executar o MPI;
- Deve ser chamada antes de qualquer outra rotina MPI.

C	**int MPI_Init (*argc, *argv)**
FORTRAN	**CALL MPI_INIT (mpierr)**

argc Apontador para um parâmetro da função **main**;

argv Apontador para um parâmetro da função **main**;

mpierr Variável inteira de retorno com o status da rotina.

mpierr=0, Sucesso (MPI_SUCCESS)
mpierr<0, Erro

C

```
#include "mpi.h"
#include <stdio.h>

int main( argc, argv )
int argc;
char **argv;
{
   MPI_Init( &argc, &argv );
   printf( "Hello world\n" );
   MPI_Finalize();
   return 0;
}
```

Fortran

```
program mpisimple
      implicit none
      integer ierr
      include 'mpif.h'
      CALL MPI_INIT(ierr)
c     print message to screen
      write(6,*) 'Hello World!'
      CALL MPI_FINALIZE(ierr)
end
```

6.3 – Finalizar um processo MPI

MPI_FINALIZE

- Finaliza o processo MPI, eliminando qualquer sinalização MPI;
- Última rotina MPI a ser executada por uma aplicação MPI;
- **Importante:** Essa rotina só deve ser chamada após se ter certeza da finalização de qualquer comunicação entre os processos.

C	**int MPI_Finalize()**
FORTRAN	**CALL MPI_FINALIZE (mpierr)**

mpierr Variável inteira de retorno com o status da rotina.

mpierr=0, Sucesso (MPI_SUCCESS)
mpierr<0, Erro

C

```
#include "mpi.h"
#include <stdio.h>

int main( argc, argv )
int argc;
char **argv;
{
   MPI_Init( &argc, &argv );
   printf( "Hello world\n" );
   MPI_Finalize();
   return 0;
}
```

Fortran

```
program mpisimple
      implicit none
      integer ierr
      include 'mpif.h'
      CALL MPI_INIT(ierr)
c     print message to screen
      write(6,*) 'Hello World!'
      CALL MPI_FINALIZE(ierr)
end
```

6.4 - Identificar um processo MPI

MPI_COMM_RANK

- Identifica o processo, dentro de um grupo de processos iniciados pelo "process manager".
- Valor inteiro, entre 0 e n-1 processos.

C	**int MPI_Comm_rank (comm, *rank)**
FORTRAN	**CALL MPI_COMM_RANK (comm, rank, mpierr)**

comm "MPI communicator";

rank Variável inteira de retorno com o número de identificação do processo;

mpierr Variável inteira de retorno com o status da rotina.

C

```
#include "mpi.h"
#include <stdio.h>

int main( argc, argv )
int argc;
char **argv;
{
   int rank;
   MPI_Init( &argc, &argv );
   MPI_Comm_rank(MPI_COMM_WORLD,&rank);
   printf( "Hello world\n" );
   MPI_Finalize();
   return 0;
}
```

Fortran

```
program mpisimple
  implicit none
  integer ierr, rank
  include 'mpif.h'
  CALL MPI_INIT(ierr)
  CALL MPI_COMM_RANK(MPI_COMM_WORLD,rank,ierr)
c print message to screen
  write(6,*) 'Hello World!'
  CALL MPI_FINALIZE(ierr)
end
```

6.5 – Informar o número de processos MPI

MPI_COMM_SIZE

- Retorna o número de processos dentro de um grupo de processos.

C	**int MPI_Comm_size (comm, *size)**
FORTRAN	**CALL MPI_COMM_SIZE (comm, size, mpierr)**

comm "MPI Communicator";

size Variável inteira de retorno com o número de processos inicializados durante uma aplicacação MPI;

mpierr Variável inteira de retorno com o status da rotina

C

```
#include "mpi.h"
#include <stdio.h>

int main( argc, argv )
int argc;
char **argv;
{
   int rank, nprocs;
   MPI_Init( &argc, &argv );
   MPI_Comm_size(MPI_COMM_WORLD,&nprocs);
   MPI_Comm_rank(MPI_COMM_WORLD,&rank);
   printf( "Hello world\n" );
   MPI_Finalize();
   return 0;
}
```

Fortran

```
program mpisimple
  implicit none
  integer ierr, rank, nprocs
  include 'mpif.h'
  CALL MPI_INIT(ierr)
  CALL MPI_COMM_SIZE(MPI_COMM_WORLD,nprocs,ierr)
  CALL MPI_COMM_RANK(MPI_COMM_WORLD,rank,ierr)
c print message to screen
  write(6,*) 'Hello World!'
  call mpi_finalize(ierr)
end
```

6.6 - Enviar menssagens no MPI

MPI_SEND

- Rotina padrão de envio de mensagens, com interrupção da execução - **"Blocking send"**.
- O processo só retorna a execução após o dado ter sido enviado.
- Após retorno, libera o "system buffer" e permite acesso ao "aplication buffer".

C	**int MPI_Send (*sndbuf, count, datatype, dest, tag, comm)**
FORTRAN	**CALL MPI_SEND (sndbuf, count, datatype, dest, tag, comm, mpierr)**

sndbuf	Endereço do dado que será enviado. Endereço do "aplication buffer";
count	Número de elementos contidos no endereço inicial, que serão enviados;
datatype	Tipo dos dados no endereço inicial;
dest	Identificação do processo destino que irá receber os dados;
tag	Rótulo de identificação da mensagem, somente numérico;
comm	"MPI communicator";
mpierr	Variável inteira de retorno com o status da rotina.

C

```
#include <stddef.h>
#include <stdlib.h>
#include "mpi.h"
main(int argc, char **argv )
{
  char message[20];
  int i,rank, size, type=99;
  MPI Status status;

  MPI_Init(&argc, &argv);
  MPI_Comm_size(MPI_COMM_WORLD,&size);
  MPI Comm rank(MPI COMM WORLD, &rank);

  if(rank == 0) {
   strcpy(message, "Hello, world");
   for (i=1; i<size; i++)
   MPI_Send(message, 13, MPI_CHAR, i,
            type, MPI_COMM_WORLD);
         }
  else
   ...
   ...
   ...

   printf( "Message from node =%d : %.13s\n",
          rank,message);
   MPI_Finalize();
}
```

Fortran

```
program hello
 include 'mpif.h'
 integer me,nt,mpierr,tag,status(MPI STATUS SIZE)
 character(12) message, inmsg

 call MPI_INIT(mpierr)
 call MPI_COMM_SIZE(MPI_COMM_WORLD,nt,mpierr)
 call MPI COMM RANK(MPI COMM WORLD,me,mpierr)

 tag = 100
 if (me .eq. 0) then
  message = 'Hello, world'
  do i=1,nt-1
     CALL MPI_SEND(message,12,MPI_CHARACTER,i,tag, &
                   MPI_COMM_WORLD,mpierr)
  enddo
  write(6,*)'node',me,':',message
  else
     ...
     ...
     ...
     write(6,*)'node',me,':',inmsg
  endif
  call MPI_FINALIZE(mpierr)
end
```

6.7 - Receber mensagens no MPI

MPI_RECV

- Rotina padrão de recebimento de mensagens, com interrupção da execução - **"Blocking receive"**.
- O processo só retorna a execução após o dado ter sido recebido e armazenado.
- Após retorno, libera o "system buffer".

C	**int MPI_Recv(*recvbuf, count, datatype, source, tag, comm,*status)**
FORTRAN	**CALL MPI_RECV(recvbuf, count, datatype, source, tag, comm, status, mpierr)**

recvbuf Endereço aonde será armazenado o dado recebido. Endereço do "aplication buffer";

count Número de elementos a serem recebidos, que serão armazenados;

datatype Tipo do dado recebido;

source Identificação do processo que enviou os dados, ou **MPI_ANY_SOURCE**;

tag Rótulo de identificação da mensagem, somente numérico, ou **MPI_ANY_TAG**;

comm MPI communicator;

status Vetor de três elementos, com informações de **source, tag e erro**;

mpierr Variável inteira de retorno com o status da rotina.

C

```
#include <stddef.h>
#include <stdlib.h>
#include "mpi.h"
main(int argc, char **argv )
{
  char message[20];
  int i,rank, size, type=99;
  MPI_Status status;

  MPI Init(&argc, &argv);
  MPI Comm size(MPI COMM WORLD,&size);
  MPI Comm rank(MPI COMM WORLD, &rank);

  if(rank == 0) {
   strcpy(message, "Hello, world");
   for (i=1; i<size; i++)
   MPI Send(message, 13, MPI CHAR, i,
            type, MPI COMM WORLD);
         }
  else
   MPI_Recv(message, 13, MPI_CHAR, 0,
            type, MPI_COMM_WORLD, &status);

   printf( "Message from node =%d : %.13s\n",
          rank,message);
   MPI_Finalize();
}
```

Fortran

```
program hello
 include 'mpif.h'
 integer me,nt,mpierr,tag,status(MPI STATUS SIZE)
 character(12) message, inmsg

 call MPI_INIT(mpierr)
 call MPI COMM SIZE(MPI COMM WORLD,nt,mpierr)
 call MPI COMM RANK(MPI COMM WORLD,me,mpierr)

 tag = 100
 if (me .eq. 0) then
  message = 'Hello, world'
  do i=1,nt-1
     CALL MPI SEND(message,12,MPI CHARACTER,i,tag, &
                   MPI_COMM_WORLD,mpierr)
  enddo
  write(6,*)'node',me,':',message
  else
     CALL MPI_RECV(inmsg,12,MPI_CHARACTER,0,tag,   &
                   MPI_COMM_WORLD,status,mpierr)
     write(6,*)'node',me,':',inmsg
  endif
  call MPI_FINALIZE(mpierr)
end
```

6.8 - MPI Message

Em MPI, a passagem de mensagens é o método básico de comunicação entre os processos durante uma execução em paralelo.

Numa rotina de envio de dados ou de recebimento de dados, uma "MPI Message" contém duas partes: o **dado**, com informações dos dados que se deseja enviar ou receber, e o **envelope** com informações da origem ou do destino dos dados.

Mensagem=dado(3 parâmetros de informações) + envelope(3 parâmetros de informações)

Ex.: CALL MPI_SEND(**sndbuf, count, datatype,** **dest, tag, comm,** mpierr)

DADO **ENVELOPE**

CALL MPI_RECV(**recvbuf, count, datatype,** **source, tag, comm,** status, mpierr)

DADO **ENVELOPE**

Tipos Básicos de Dados no C

MPI_CHAR	**signed char**
MPI_SHORT	**signed short int**
MPI_INT	**signed int**
MPI_LONG	**signed long int**
MPI_UNSIGNED_CHAR	**unsigned char**
MPI_UNSIGNED_SHORT	**unsigned short int**
MPI_UNSIGNED	**unsigned int**
MPI_UNSIGNED_LONG	**unsigned long int**
MPI_FLOAT	**float**
MPI_DOUBLE	**double**
MPI_LONG_DOUBLE	**long double**

Tipos Básicos de Dados no FORTRAN

MPI_INTEGER	**INTEGER**
MPI_REAL	**REAL**
MPI_DOUBLE_PRECISION	**DOUBLE**
MPI_COMPLEX	**COMPLEX**
MPI_LOGICAL	**LOGICAL**
MPI_CHARACTER	**CHARACTER**

LABORATÓRIO 1 - Rotinas Básicas do MPI

Exercício 1

1 - Caminhe para a pasta do primeiro exercício do laboratório.

cd ./lab01/ex1

2 - Compile o programa **hello.f** ou **hello.c** de acordo com a instalação MPI do ambiente.

IBM : **mpxlf hello.f -o hello** **ou** **mpcc hello.c -o hello**

INTEL : **ifort hello.f -o hello -lmpi** **ou** **icc hello.c -o hello -lmpi**

MPICH2: **mpif77 hello.f -o hello** **ou** **mpicc hello.c -o hello**

3 - Caso utililize MPICH2, crie um arquivo com uma configuração de máquinas existentes no ambiente.

OBS: Se a máquina ou nó possuir ***n*** "cores", repita o nome dessa máquina ***n*** vezes

Ex.: Ambiente com uma duas máquinas "quad-core": maq01 e maq02

vi maquinas (Outros editores: **pico** ou **nano**)

```
maq01
maq01
maq01
maq01
maq02
maq02
maq02
maq02
```

4 - Execute o programa várias vezes, alterando o número de processos.

IBM : **poe ./hello -procs *n* -hostfile *./arquivo***

INTEL : **ulimit –v unlimited**

mpirun -np *n* ./hello

MPICH2: **mpiexec ./hello -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

Exercício 2

Os programas apresentados nos exercícios dos laboratórios seguem o modelo **SPMD ("Single Program" – "Multiple Data"**), ou seja, o mesmo código, executa como um processo pai, enviando os dados e coordenando os processos, e como processo filho, recebendo os dados, processando tarefas e devolvendo os resultados ao processo pai.

No caso do próximo exercício, o processo pai envia uma mensagem ("Hello world") para todos os processos filhos e imprime a sua mensagem na "saída padrão". Os processos filhos, recebem a mensagem e, também imprimem-na, na "saída padrão".

1 - Caminhe para a pasta com o segundo exercício do laboratório.

cd ./lab01/ex2

O exercício está em alterar o programa, de maneira que, cada processo filho receba a mensagem enviada pelo processo pai, mas não faz nada com ela, e envia a sua identificação MPI para o processo pai. O processo pai recebe a identificação do processo filho e imprime essa identificação junto com a mensagem "Hello Back".

2 - Adicione as rotinas necessárias ao programa em FORTRAN ou em C **substituindo as linhas que possuem setas por rotinas do MPI, e complete a lógica de alguns comandos**.

vi hello.ex1.f **ou** **vi hello.ex1.c** (Outros editores: **pico** ou **nano**)

3 - Compile o programa:

IBM : **mpxlf hello.ex1.f -o hello2** **ou** **mpcc hello.ex1.c -o hello2**

INTEL : **ifort hello.ex1.f -o hello2 -lmpi** **ou** **icc hello.ex1.c -o hello2 -lmpi**

MPICH2 : **mpif77 hello.ex1.f -o hello2** **ou** **mpicc hello.ex1.c -o hello2**

4 - Execute o programa:

IBM : **poe ./hello2 -procs *n* -hostfile *./arquivo***

INTEL : **mpirun -np *n* ./hello2**

MPICH2 : **mpiexec ./hello2 -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

5 - Altere novamente o programa e na rotina de "receive" do processo pai, substitua o parâmetro que identifica a origem da mensagem, pela palavra reservada: **MPI_ANY_SOURCE**.

6 - Compile e execute novamente. Percebeu alguma diferença no padrão da resposta?

Exercício 3

1 - Caminhe para o diretório com o terceiro exercício do laboratório.

cd ./lab01/ex3

Um programa pode utilizar a idéia do parâmetro **tag** em rotinas de "send" e "receive" para distinguir as mensagens que estão sendo enviadas ou recebidas.

2 - Adicione as rotinas necessárias ao programa em FORTRAN ou em C, **substituindo as linhas que possuem setas por rotinas do MPI,** de maneira que, o processo pai envie duas mensagens ("Hello" e "World") para cada processo filho, utilizando-se de duas **tags** diferentes. Os processos filhos deverão receber as mensagens na ordem invertida e irão imprimir o resultado na "saída padrão".

vi hello.ex2.f **ou** **vi hello.ex2.c** (Outros editores: **pico** ou **nano**)

3 - Compile o programa:

IBM : **mpxlf hello.ex2.f -o hello3** **ou** **mpcc hello.ex2.c -o hello3**

INTEL : **ifort hello.ex2.f -o hello3 -lmpi ou** **icc hello.ex2.c -o hello3 -lmpi**

MPICH2 : **mpif77 hello.ex2.f -o hello3** **ou** **mpicc hello.ex2.c -o hello3**

4 - Execute o programa:

IBM : **poe ./hello3 -procs *n* -hostfile *./arquivo***

INTEL : **mpirun -np *n* ./hello3**

MPICH2 : **mpiexec ./hello3 -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

Exercício 4

1 - Caminhe para o diretório com o quarto exercício do laboratório.

cd ./lab01/ex4

Neste exercício, o processo pai inicia um vetor de 60.000 elementos, e distribui partes desse vetor para vários processos filhos. Cada processo filho recebe a sua parte do vetor principal, efetua um cálculo simples e devolve os dados para o processo mestre.

2 - Adicione as rotinas necessárias ao programa em FORTRAN ou em C, **substituindo as linhas que possuem setas por rotinas do MPI.**

vi mpi.ex1.f **ou** **vi mpi.ex1.c** (Outros editores: **pico** ou **nano**)

3 - Compile o programa:

IBM : **mpxlf mpi.ex1.f -o vetor** **ou** **mpcc mpi.ex1.c -o vetor**

INTEL : **ifort mpi.ex1.f -o vetor -lmpi** **ou** **icc mpi.ex1.c -o vetor -lmpi**

MPICH2 : **mpif77 mpi.ex1.f -o vetor** **ou** **mpicc mpi.ex1.c -o vetor**

4 - Execute o programa:

IBM : **poe ./vetor -procs *n* -hostfile ./*arquivo***

INTEL : **mpirun -np *n* ./vetor**

MPICH2 : **mpiexec ./vetor -np *n* -f ./*arquivo***

n* = *número de processos
arquivo* = *nome do arquivo de máquinas

OBS: O número de processos filhos deve ser um múltiplo do tamanho do vetor.

Exercício 5

O objetivo desse exercício e demonstrar a execução paralela de vários códigos diferentes e comunicando-se entre si, ou seja, vamos trabalhar com o modelo **MPMD** (**"Multiple Program" – "Multiple Data"**). Um código irá executar como um processo pai, enviando os dados e coordenando os processos, e um outro código executará como processo filho, recebendo os dados, processando tarefas e devolvendo os resultados ao processo pai.

1 - Caminhe para o diretório com o quinto exercício do laboratório.

cd ./lab01/ex5

2 - Vamos trabalhar com o código da solução do exercício 4 que está pronto para ser dividido em dois programas. Faça duas cópias do programa em C ou Fortran.

cp mpi.ex1.c pai.c ou cp mpi.ex1.f pai.f
cp mpi.ex1.c filho.c ou cp mpi.ex1.f filho.f

3 - Edite separadamente cada arquivo, elimine ou mantenha as linhas referentes a execução como processo pai e a execução como processo filho. A parte inicial do programa mpi.ex1, será comum aos programas pai e filho, mas no programa filho, será necessário acrescentar a rotina de finalização do MPI.

vi pai.f ou vi pai.c (Outros editores: **pico** ou **nano**)
vi filho.f ou vi filho.c

4 - Compile cada um dos programas:

IBM : **mpxlf pai.f -o pai ou mpcc pai.c -o pai**
mpxlf filho.f -o filho ou mpcc filho.c -o filho

INTEL : **ifort pai.f -o pai -lmpi ou icc pai.c -o pai -lmpi**
ifort filho.f -o filho -lmpi ou icc filho.c -o filho -lmpi

MPICH2: **mpif77 pai.f -o pai ou mpicc pai.c -o pai**
mpif77 filho.f -o filho ou mpicc filho.c -o filho

5 - Execute o programa:

IBM : É necessário definir um arquivo de execução dos processos. Veja o exemplo abaixo, para a execução de 1 processo **pai** e 6 processos **filho.**

vi executa (Outros editores: **pico** ou **nano**)

```
./pai
./filho
./filho
./filho
./filho
./filho
./filho
```

poe -procs 7 -pgmmodel mpmd -cmdfile ./executa -hostfile ./*arquivo*

As opções:	**-pgmmodel**	Define o modelo de execução (spmd ou mpmd);
	-cmdfile	Indica o arquivo com o nome dos executáveis;
	-hostfile	Indica o arquivo com o nome das máquinas;
	-procs	Indica o número de processos. Tem que está de acordo com o número de executáveis indicado na opção **cmdfile.**

INTEL : **mpirun -np *n* ./pai : -np *n* ./filho**

MPICH2: **mpiexec -f ./*arquivo* -np *n* ./pai : -np *n* ./filho**

n = número de processos
arquivo = nome do arquivo de máquinas

OBS: O número de processos filhos deve ser um múltiplo do tamanho do vetor.

Exercício 6

1 - Caminhe para o diretório com o sexto exercício do laboratório.

cd ./lab01/ex6

Este programa calcula o valor de **PI**, através de um algorítmo que soluciona uma integral. A idéia do exercício é de perceber erros de lógica na execução de um programa. O programa não está funcionando corretamente; **corrija dois erros** bem simples, um de cálculo e outro de finalização dos resultados.

2 - Compile o programa com os erros:

IBM : **mpxlf karp.mpi.f -o pi** **ou** **mpcc karp.mpi.c -o pi**

INTEL : **ifort karp.mpi.f -o pi -lmpi** **ou** **icc karp.mpi.c -o pi -lmpi**

MPICH2 : **mpif77 karp.mpi.f -o pi** **ou** **mpicc karp.mpi.c -o pi**

3 - Execute o programa e verifique os erros:

IBM : **poe ./pi -procs *n* -hostfile *./arquivo***

INTEL : **mpirun -np *n* ./pi**

MPICH2 : **mpiexec ./pi -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

4 - Edite o programa e corrija os erros:

vi karp.mpi.f **ou** **vi karp.mpi.c** (Outros editores: **pico** ou **nano**)

5 - Compile e execute novamente o programa para verificar se os problemas foram corrigidos.

7 – Métodos de Comunicação "Point-To-Point"

- Numa comunicação "Point-to-Point", um processo envia uma mensagem e um segundo processo, recebe.

- Existem várias opções de programação utilizando-se comunicação "Point-to-Point". Opções que incluem:

  Quatro métodos de comunicação: **synchronous, ready, buffered,** e **standard**

  Duas formas de processamento: **blocking** e **non-blocking**.

- Existem quatro rotinas "blocking send" e quatro rotinas "non-blocking send", correspondentes aos quatro métodos de comunicação.

- A rotina de "receive" não especifica o método de comunicação. Simplesmente, ou a rotina é "blocking" ou, "non-blocking".

7.1 - "Blocking Synchronous Send"

C	**int MPI_Ssend (*buf, count, datatype, dest, tag, comm)**
FORTRAN	**CALL MPI_SSEND (buf, count, datatype, dest, tag, comm, ierror)**

Quando um **MPI_Ssend** é executado, o processo que irá enviar a mensagem, primeiro, envia um sinal ao processo que recebe para verificar se já existe um "receive" ativo, e se não existir, **espera** até que seja executado um "receive", para então, iniciar transferência dos dados.

Overheads

System overhead Ocorre devido a cópia da mensagem do "send buffer" para a rede e da rede para o "receive buffer". Depende do tamanho da mensagem.

Synchronization overhead Ocorre devido ao tempo de espera de um dos processos pelo sinal de OK de outro processo.

OBS: Neste modo, o **"Synchronization overhead"**, pode ser significante.

Blocking Synchronous Send e Blocking Receive

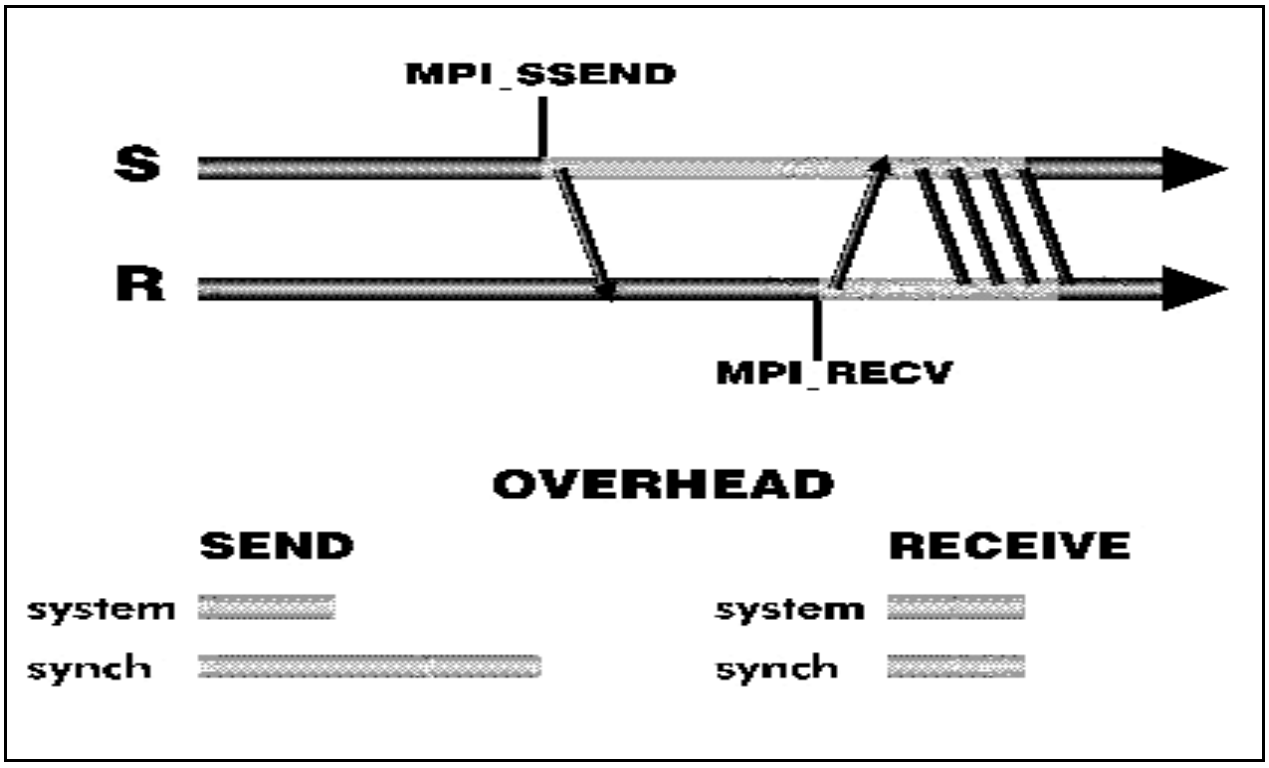

7.2 - "Blocking Ready Send"

C	**int MPI_Rsend (*buf, count, datatype, dest, tag, comm)**
FORTRAN	**CALL MPI_RSEND (buf, count, datatype, dest, tag, comm, ierror)**

Quando um **MPI_Rsend** é executado a mensagem é enviada imediatamente, sem que haja qualquer controle no envio, ou qualquer controle no recebimento – as ações internas do MPI de "handshake". É essêncial que já exista um "receive" ativo no processo que irá receber, do contrário as consequências são imprevisíveis.

Overheads

System overhead Tempo padrão. Depende do tamanho da mensagem.

Synchronization overhead É mínimo ou nada no processo que envia, mas no processo que recebe, pode ser muito alto, dependendo do momento que é executada a rotina de "receive".

OBS: Atenção, este modo somente deverá ser utilizado se o programador tiver certeza que uma rotina de "receive", em qualquer processo, tenha sido executada, antes do processo que envia executar um **MPI_Rsend**.

Blocking Ready Send e Blocking Receive

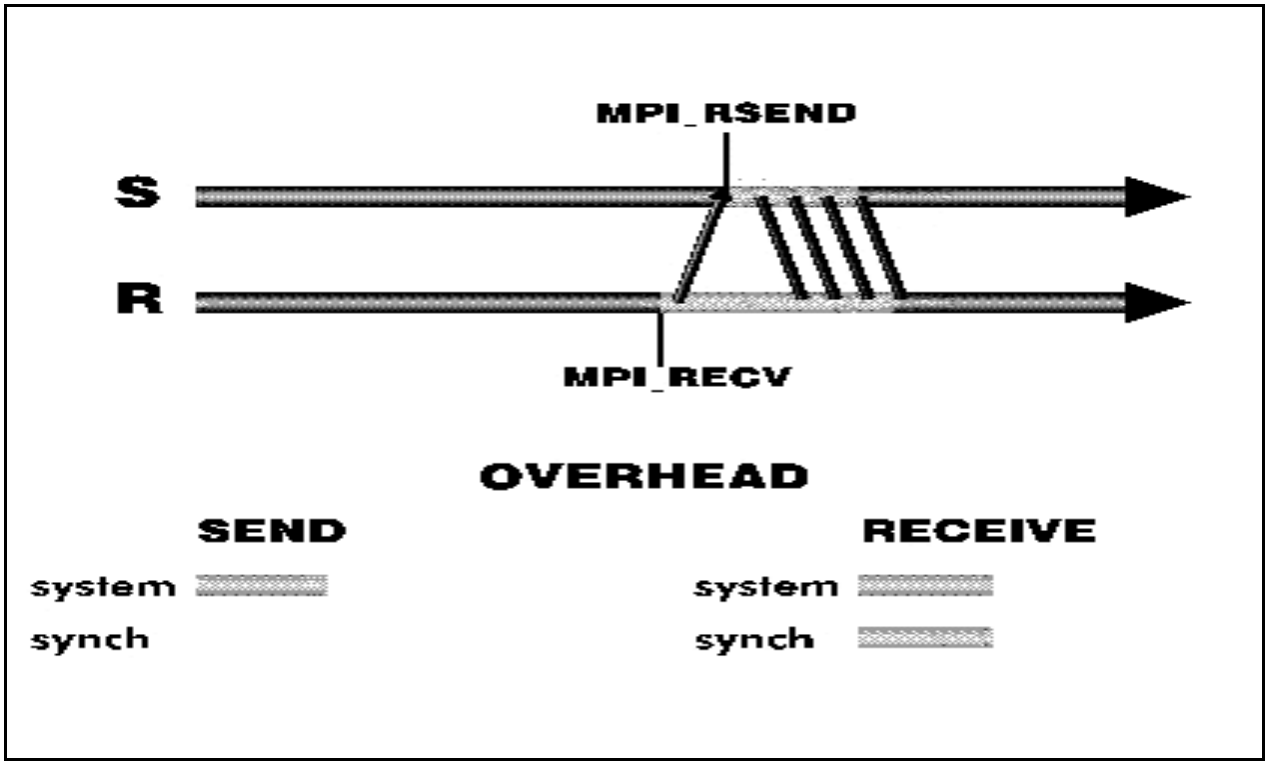

7.3 - "Blocking Buffered Send"

C	**int MPI_Bsend (*buf, count, datatype, dest, tag, comm)**
FORTRAN	**CALL MPI_BSEND (buf, count, datatype, dest, tag, comm, ierror)**

Quando um **MPI_Bsend** é executado a mensagem é copiada do endereço de memória ("Aplication buffer") para um "buffer" definido pelo usuário, e então, retorna a execução normal do programa. É aguardado a execução de um “receive” do processo que irá receber, para descarregar o "buffer".

Overheads

System overhead Aumenta em relação ao padrão, pois ocorrem duas trasnferências de dados, uma devido a cópia da mensagem do "Aplication buffer" para o "buffer" definido pelo usuário e a outra para o processo que irá receber os dados.

Synchronization overhead Não existe no processo que envia, e no processo que recebe. irá depender do momento da execução do “receive”.

OBS: Atenção, este método, só utiliza o “buffer” definido pela rotina **MPI_Buffer_attach,** que deverá ser utilizada antes da execução de um **MPI_Bsend.**

Blocking Buffered Send e Blocking Rceive

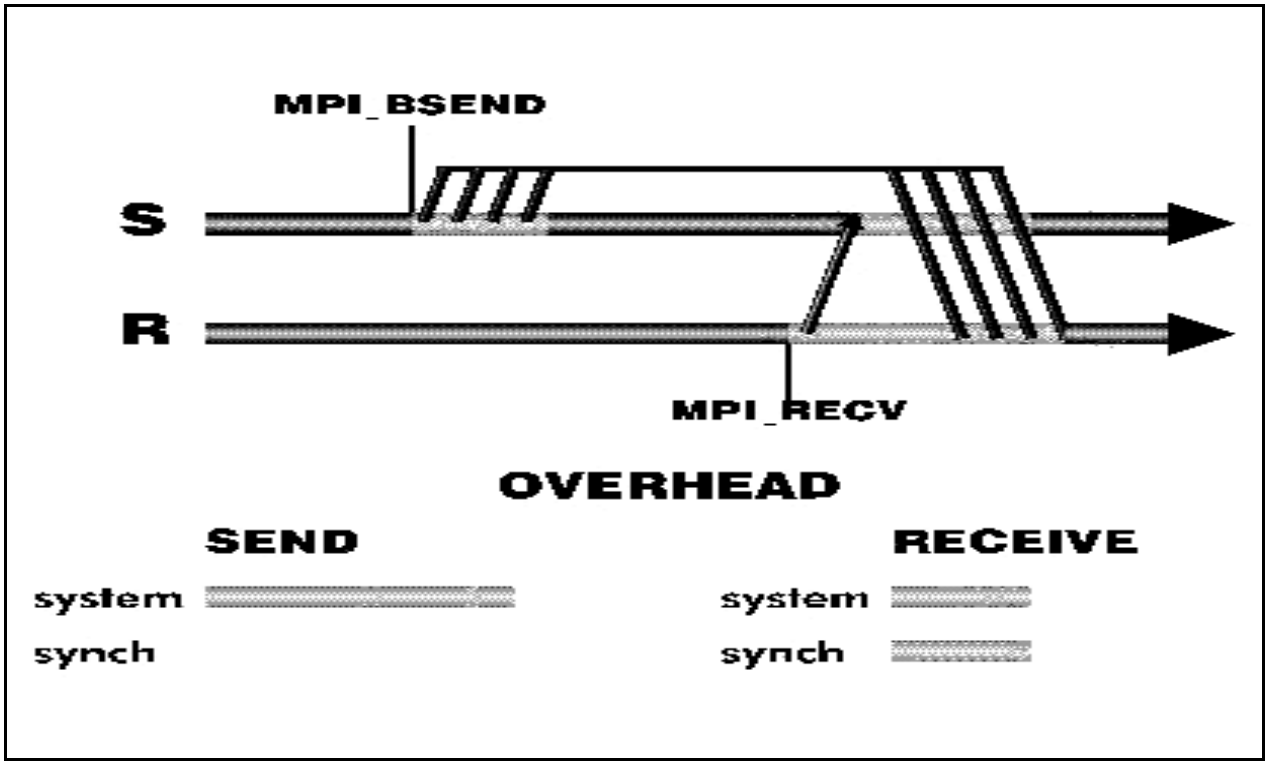

7.4 - "Blocking Standard Send"

C	**int MPI_Send(*buf, count, datatype, dest, tag, comm)**
FORTRAN	**CALL MPI_SEND(buf, count, datatype, dest, tag, comm, ierror)**

O método padrão de envio de mensagens, trabalha utilizando “buffers” do sistema. O tamanho desses “buffers” depende da implementação MPI utilizada, e que pode variar entre 4K, 8K, 16K, 32K ou 64K bytes de memória, e também, de acordo com o número de processos iniciados. Na implementação inicial e básica do MPI, o “buffer” definido é de 4K, portanto, vamos analisar o envio de mensagens com esse padrão de “buffer”.

Message <= 4K

Quando **MPI_Send** é executado, a mensagem é imediatamente transmitida para o processo que irá receber a mensagem, e fica armazenada no “buffer” desse processo até que seja executado um “receive”.

Overheads

System Overhead	Tempo padrão. Depende do tamanho da mensagem.
Synchronization overhead	Mínimo, pois não existe a necessidade de sincronização dos processos.

Blocking Standard Send e Blocking Receive
Message <= 4K

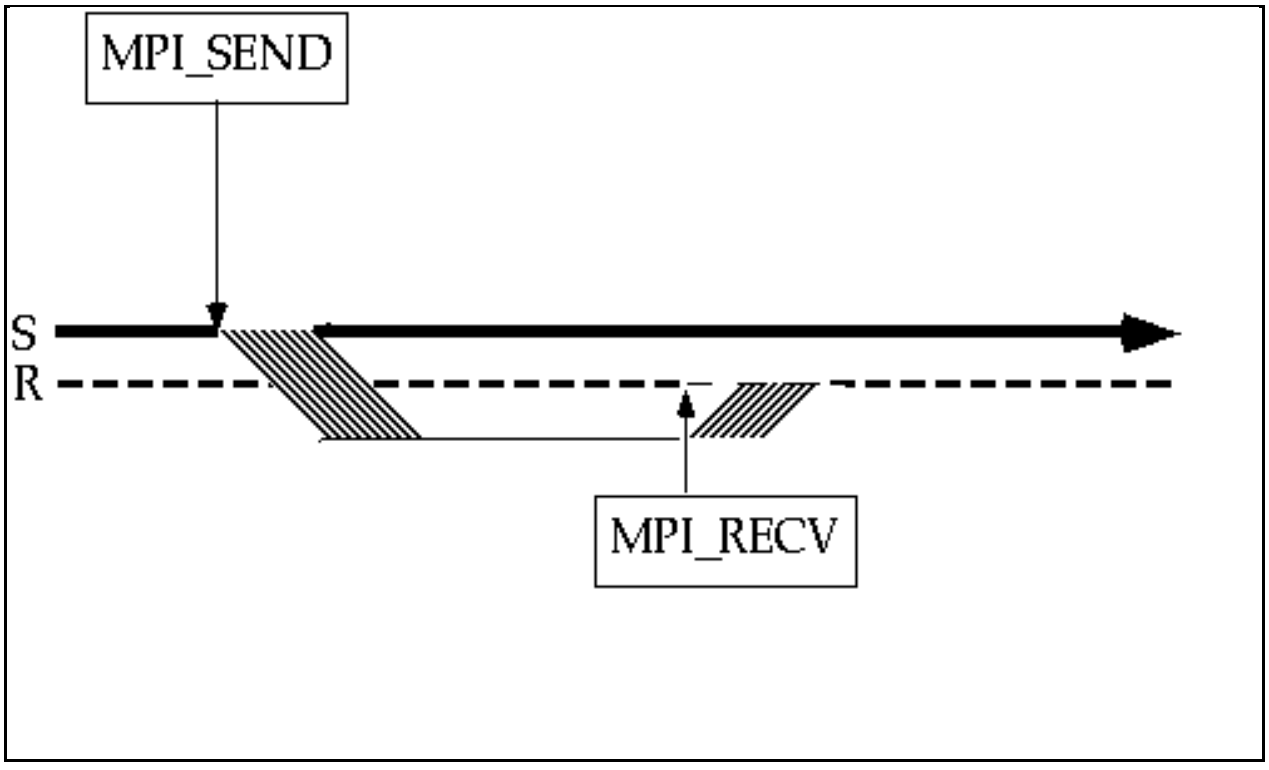

Message > 4K

Quando **MPI_Send** é executado e a mensagem que será enviada é maior que o "buffer" do sistema, o método síncrono é utilizado, pois não é possível garantir o espaço do receive "buffer". É necessário aguardar a execução de um "receive" para que a mensagem seja transmitida.

Blocking Standard Send e Blocking Receive
Message > 4K

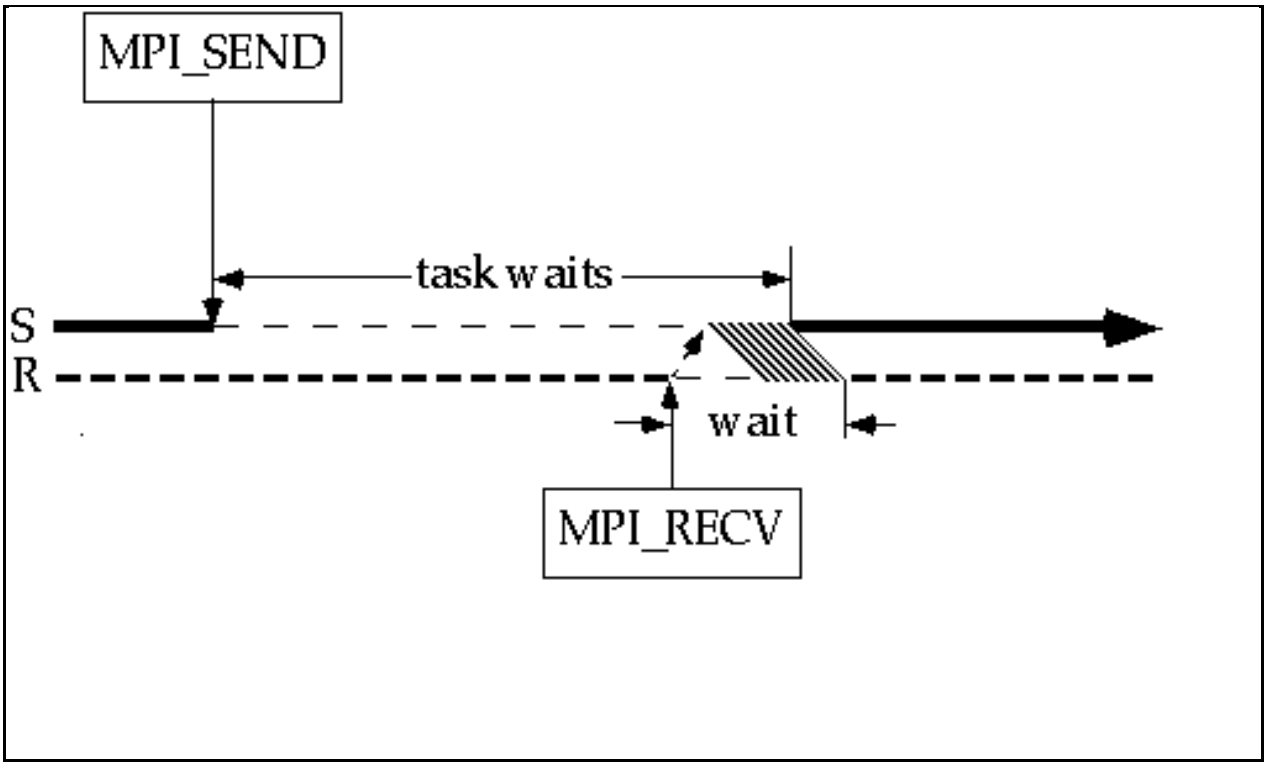

7.5 – Rotina MPI_Buffer_attach

C	**int MPI_Buffer_attach (*buf, size)**
FORTRAN	**CALL MPI_BUFFER_ATTACH (buf, size, ierror)**

buf Variável que identifica o endereço do "buffer";

size Variável inteira que determina o tamanho do "buffer" (em número de bytes);

ierror Variável inteira com status da execução da rotina.

Rotina MPI que é utilizada em conjunto com a rotina “buffered send” (MPI_Bsend). Define para o MPI, um "buffer" de tamanho específico, para ser utilizado no envio de mensagens. Somente a rotina “buffered send” poderá utilizar esse endereço definido.

OBS: Somente um "buffer" poder ser definido por processo, durante a execução da aplicação. Se for necessário definir um novo “buffer”, deve-se, primeiro, eliminar o “buffer” anterior.

7.6 – Rotina MPI_Buffer_detach

C	**int MPI_Buffer_detach (*buffer, *size)**
FORTRAN	**CALL MPI_BUFFER_DETACH (buf, size, ierror)**

buf Variável que identifica o endereço do "buffer", que será eliminado;

size Variável inteira de retorno com informação do tamanho do "buffer" (em número de bytes) que foi eliminado;

ierror Variável inteira com status da execução da rotina.

Elimina o "buffer" que foi iniciado anteriormente para o MPI. Isso as vezes é necessário para liberar espaço de memória utilizada pelo processo. Esta operação bloqueia a execução do programa até que a transmissão da mensagem tenha sido terminado.

7.7 - "Deadlock"

Fenômeno comum quando se utiliza "blocking communication". Acontece quando **todos os processos** estão aguardando por eventos que ainda não foram iniciados.

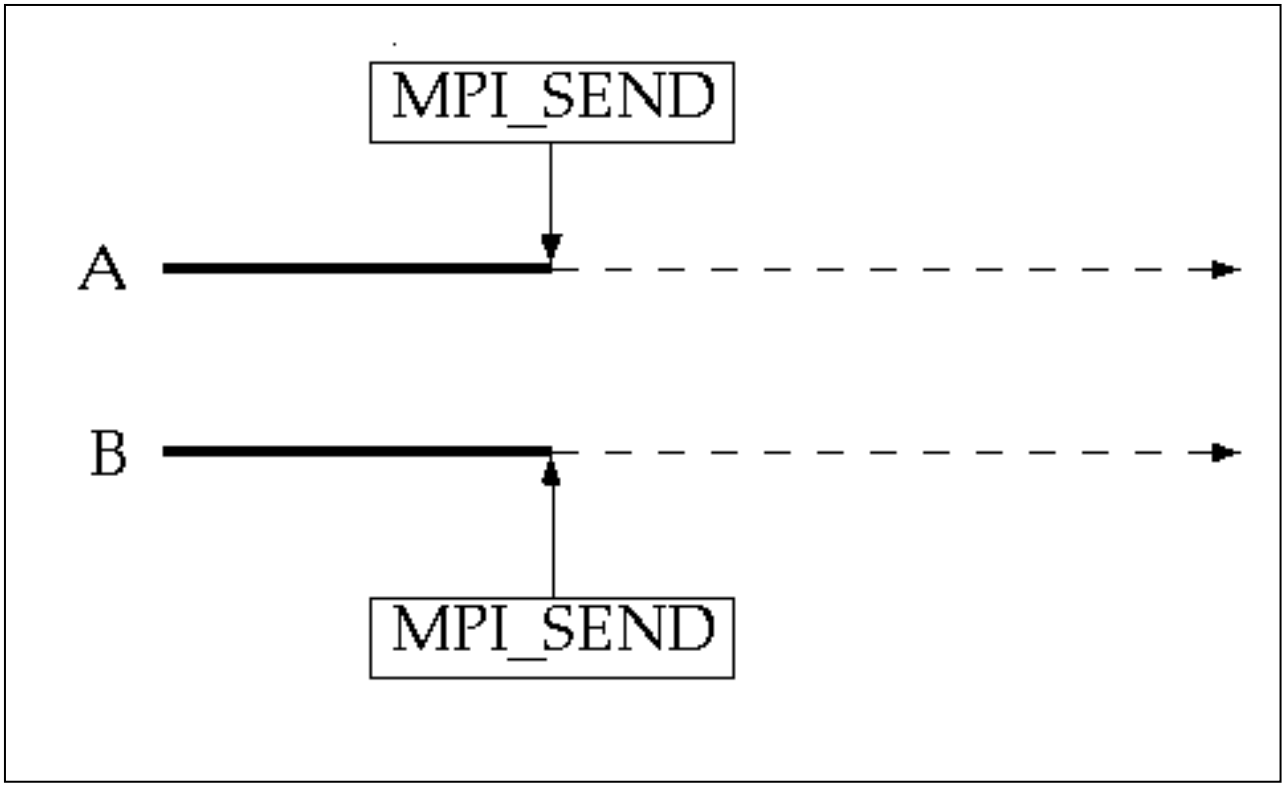

- Organize os eventos de envio e recebimento de mensagens na sua aplicação, de maneira que, os eventos de envio de mensagens casem com os eventos de recebimento antes de enviar novas mensagens;

- Utilize as rotinas "non-blocking communication".

7.8 – Rotinas de Comunicação "Non-blocking"

- Em uma comunicação **"blocking"**, a execução do programa é suspensa até o "buffer" de envio ou recebimento de mensagens estar liberado para uso novamente. Quando se executa um **"blocking send"**, a execução do processo para, e dependendo do método utilizado, aguarda por determinados eventos acontecerem:

Syncronous	Aguarde sinal de receive do processo que irá receber a mensagem;
Ready	Aguarda a liberação do "Aplication buffer", após envio dos dados para a rede;
Buffered	Aguarda a liberação do "Aplication buffer", após a cópia dos dados para o novo "buffer";
Standard	Aguarda a liberação do "Aplication buffer", após a cópia dos dados para o "receive buffer".

- Em uma comunicação **"non-blocking"**, a execução do programa continua imediatamente após ter sido iniciada a comunicação; não existe a espera por qualquer evento, e o programador não tem idéia se a mensagem já foi enviada ou recebida. Em uma comunicação **"non-blocking"**, será necessário bloquear a continuação da execução do programa, ou averiguar o status do "system buffer", antes de reutilizá-lo.

- Existem algumas rotinas MPI, específicas para verificar o status do "buffer" de envio e recebimento de mensagens:

MPI_Wait
MPI_Test

- O nome das subrotinas **"non-blocking",** iniciam com a letra **I,** (**MPI_I**xxxx), e possuem mais um parâmetro de retorno, com a informação da situação do "buffer".

- Parâmetro de retorno **"request"**; variável inteira utilizada nas rotinas "non-blocking", possui ação transparente, ou seja, é apenas utilizada como parâmetro de ligação entre as rotinas de envio e recebimento de mensagens, com as rotinas de controle do status do "buffer", **MPI_Wait, MPI_Test.**

7.8.1 - Rotina MPI_Issend - Non-Blocking Synchronous Send

C	**int MPI_Issend(*buf, count, datatype, dest, tag, comm, *request)**
FORTRAN	**CALL MPI_ISSEND(buf, count, datatype, dest, tag, comm, request, ierror)**

7.8.2 - Rotina MPI_Irsend - Non-Blocking Ready Send

C	**int MPI_Irsend(*buf, count, datatype, dest, tag, comm,*request)**
FORTRAN	**CALL MPI_IRSEND(buf, count, datatype, dest, tag, comm, request, ierror)**

7.8.3 - Rotina MPI_Ibsend - Non-Blocking Buffered Send

C	**int MPI_Ibsend(*buf, count, datatype, dest, tag, comm, *request)**
FORTRAN	**CALL MPI_IBSEND(buf, count, datatype, dest, tag, comm, request, ierror)**

7.8.4 - Rotina MPI_Isend - Non-Blocking Standard Send

C	**int MPI_Isend(*buf, count, datatype, dest, tag, comm, *request)**
FORTRAN	**CALL MPI_ISEND(buf, count, datatype, dest, tag, comm, request, ierror)**

7.8.5 - Rotina MPI_Irecv - Non-Blocking Receive

C	**int MPI_Irecv(*buf, count, datatype, source, tag, comm, *request)**
FORTRAN	**CALL MPI_IRECV(buf, count, datatype, source, tag, comm, request, ierror)**

Non-Blocking Standard Send e Non-Blocking Receive
Message <= 4K

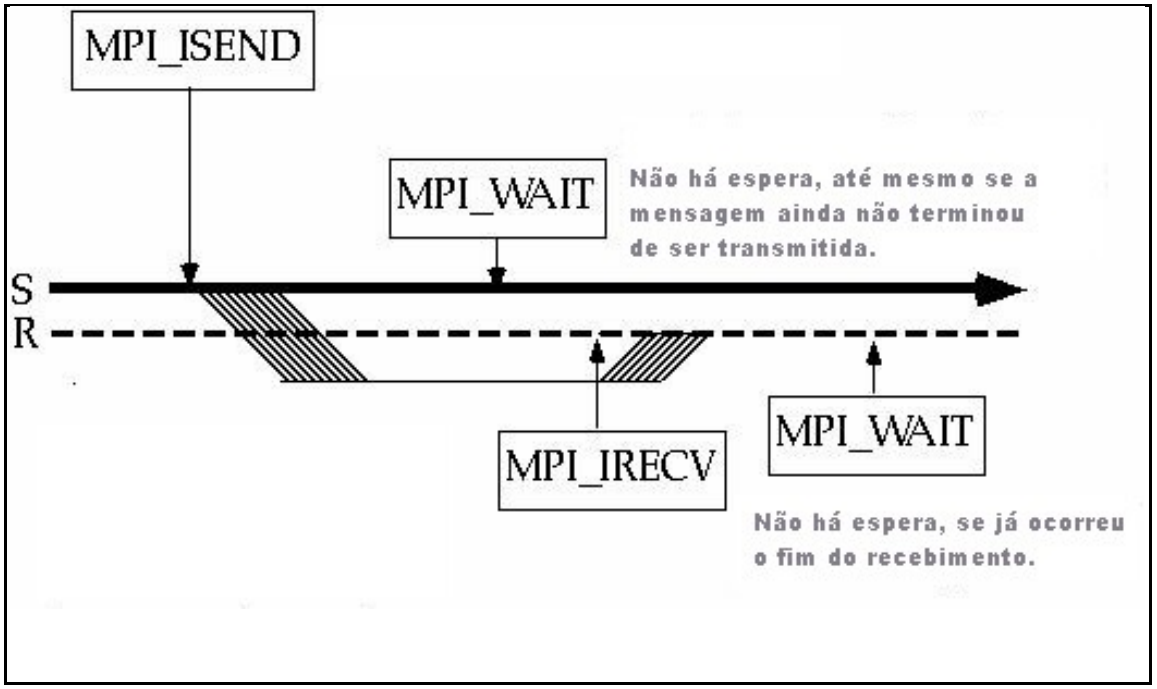

Non-Blocking Standard Send e Non-Blocking Receive
Message > 4K

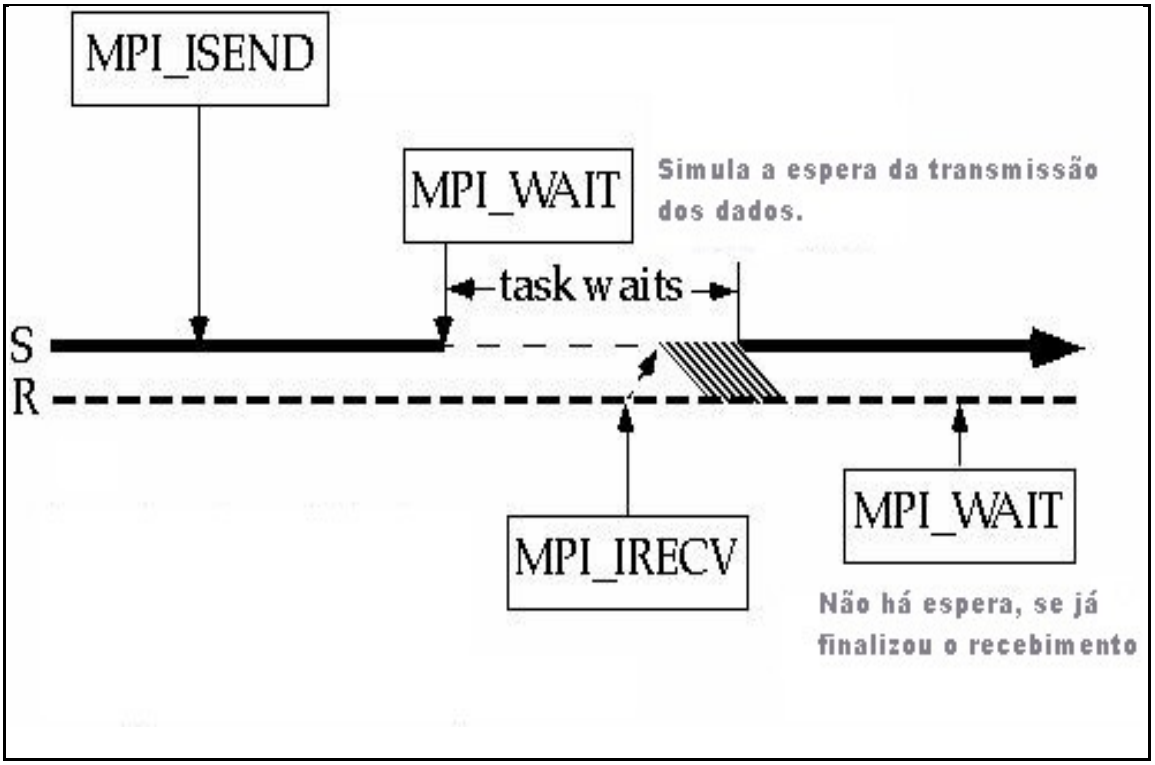

7.9 – Rotinas Auxiliares as Rotinas "Non-blocking"

7.9.1 - Rotina MPI_Wait

C	**int MPI_Wait (*request, *status)**
FORTRAN	**CALL MPI_WAIT (request, status, ierror)**

request Variável inteira "transparente", que armazena a informação sobre a transferência dos dados pelo processo. Essa informação é fornecida pelas rotinas "non-blocking send" ;

status Vetor com informações da mensagem, enviada ou recebida;

ierror Variável inteira com o status da execução da rotina.

Esta rotina bloqueia a execução do programa até que seja completada a ação identificada pela variável **request** (de ativo para inativo):

active "buffer" ativo. Transferência de dados em andamento;
inactive ou null "buffer" inativo. Transferência de dados finalizada.

"blocking" → "deadlock"

```
If( rank == 0 ) Then

 Call MPI_send(buffer1, 1, MPI_integer, 1, 10, &
               MPI_comm_world, error )

 Call MPI recv(buffer2, 1, MPI integer, 1, 20, &
               MPI comm world, status, error )

Else If( rank == 1 ) Then

 Call MPI send(buffer2, 1, MPI integer, 0, 20, &
               MPI comm world, error )

 Call MPI_recv(buffer1, 1, MPI_integer, 0, 10, &
               MPI_comm_world, status, error )

End If
```

"non-blocking"→ "no deadlock"

```
If( rank == 0 ) Then

 Call MPI Isend(buffer1, 1, MPI integer, 1, 10, &
                MPI_comm_world, REQUEST, error )

 Call MPI_Irecv(buffer2, 1, MPI_integer, 1, 20, &
                MPI_comm_world, REQUEST, error )

Else If( rank == 1 ) Then

 Call MPI_Isend(buffer2, 1, MPI_integer, 0, 20, &
                MPI_comm_world, REQUEST, error )

 Call MPI Irecv(buffer1, 1, MPI integer, 0, 10, &
                MPI_comm_world, REQUEST, error )

End If

Call MPI_wait( REQUEST, status ) ! ???

Call MPI_finalize( error )
```

7.9.2 - Rotina MPI_Test

C	**int MPI_Test(*request, *flag, *status)**
FORTRAN	**CALL MPI_TEST(request, flag, status, ierror)**

request Variável inteira "transparente", que armazena a informação sobre a transferência dos dados pelo processo. Essa informação é fornecida pelas rotinas "non-blocking send" ;

flag Variável lógica que identifica o valor de **request**:

"buffer" inativo	**MPI_REQUEST_NULL**	**flag=true**
"buffer" ativo	**MPI_REQUEST_ACTIVE**	**flag=false**

status Vetor com informações da mensagem;

ierror Variável inteira com o status da execução da rotina.

Essa rotina apenas informa se uma rotina "non-blocking" foi concluída ou não.

7.10 – Conclusões

- O modo **"Synchronous"** é o mais seguro e ao mesmo tempo, o mais portável (Qualquer tamanho de mensagens, em qualquer arquitetura, em qualquer ordem de execução de "send" e "receive").

- **O modo "Ready" possui o menor índice total de "overhead", no entanto, a execução de um** "receive" no processo destino, deve preceder a execução de um "send" no processo de origem.

- O modo **"Buffered"** permite o controle no tamanho do "buffer".

- O modo **"Standard"** é a implementação básica do MPI. Possui excelente performance.

- As rotinas **"Non-blocking"** possuem a vantagem de continuar a execução de um programa, mesmo se a mensagem ainda não tiver sido enviada. Elimina o "deadlock" e reduz o "system overhead", no geral.

- As rotinas **"Non-blocking"** necessitam de um maior controle, que pode ser feito por rotinas auxiliares.

LABORATÓRIO 2 - Comunicação Point-to-Point

Exercício 1

1 - Caminhe para o diretório com o primeiro exercício do laboratório.

cd ./lab02/ex1

Este exercício tem como objetivo, demonstrar e comparar a performance entre os quatro métodos de comunicação "blocking send", a partir da transmissão de um vetor de dados, que pode simular o tamanho de "buffers", a partir de 4Kbytes.

OBS: O programa não mede o tempo de comunicação completo e nem o total do "system overhead", apenas o tempo de transferência de dados das rotinas de "send".

2 - Inicialmente, o programa define um vetor de dados, que utiliza 4Kbytes de memória.

C mlen=1024 (elementos do tipo integer=4 bytes, total de 4Kbytes)
Fortran imlen=1024 (elementos do tipo integer=4 bytes, total de 4Kbytes)

3 - Compile o programa

OBS: A versão em Fortran depende do compilador instalado e de suas rotinas medição de tempo. No exercício existe um programa alternativo, caso o original não funcione.

IBM : **mpxlf blocksends.f -o bks** **ou** **mpcc blocksends.c -o bks**

INTEL : **ifort blocksends.f -o bks -lmpi** **ou** **icc blocksends.c -o bks -lmpi**

MPICH2 : **mpif77 blocksends.f -o bks** **ou** **mpicc blocksends.c -o bks**

4 - Execute o programa iniciando apenas **dois processos** para que seja possível realizar a medição de tempos. Execute pelo menos três vezes para se ter uma média dos tempos;

IBM : **poe ./bks -procs 2 -hostfile *./arquivo***

INTEL : **ulimit –v unlimited**

mpirun -np 2 ./bks

MPICH2 : **mpiexec ./bks -np 2 -f *./arquivo***

arquivo = nome do arquivo de máquinas

5 - Edite o programa e altere o número de elementos do vetor, principalmente em relação aos possíveis limite de "buffers" do ambiente:

vi blocksends.f **ou** **vi blocksends.c** (Outros editores: **pico** ou **nano**)

1024 (<=4K) e **1025** (>4K)	**2048** (<=8K) e **2049** (> 8K)	**4096** (<=16K) e **4097** (> 16K)
8192 (<=32K) e **8193** (>32K)	**12288** (<=48K) e **16289** (>48K)	**16384** (<=64K) e **16385** (>64K)

6 - Compile e execute novamente o programa. OBS: Normalmente o **"send standard"** possui excelente performance, mas quando o tamanho do "buffer" é ultrapassado, a sua performance piora bastante.

Exercício 2

1 - Caminhe para o diretório com o segundo exercício do laboratório.

cd ./mpi/lab02/ex2

Este programa tem por objetivo demonstrar a utilização das rotinas "non-blocking" para evitar "deadlock".

2 - Compile o programa:

IBM : **mpxlf deadlock.f -o dlock** **ou** **mpcc deadlock.c -o dlock**

INTEL : **ifort deadlock.f -o dlock -lmpi** **ou** **icc deadlock.c -o dlock -lmpi**

MPICH2 : **mpif77 deadlock.f -o dlock** **ou** **mpicc deadlock.c -o dlock**

4 - Execute o programa, iniciando apenas **dois processos**.

IBM : **poe ./dlock -procs 2 -hostfile *./arquivo***

INTEL : **mpirun ./dlock -np 2 ./dlock**

MPICH2 : **mpiexec ./dlock -np 2 -f *./arquivo***

arquivo = nome do arquivo de máquinas

OBS: O programa irá imprimir várias linhas na saída padrão, e então para. Será necessário executar um **<*ctrl*> <*c*>**, para finalizar o programa.

5 - Edite o programa e corrija o problema. **O que será necessário alterar ???**

vi deadlock.f **ou** **vi deadlock.c** (Outros editores: **pico** ou **nano**)

6 - Compile e execute novamente para verificar se o problema foi corrigido.

Exercício 3

1 - Caminhe para o diretório com o terceiro exercício do laboratório.

cd ./lab02/ex3

Este programa tenta demonstrar o tempo perdido em "synchronization overhead" para mensagens maiores de 4Kbytes. A rotina externa (sleep), utilizada nos programas, serve para simular tempo de processamento.

2 - Compile primeiro a rotina *sleep*, criando apenas o código objeto (opção **-c**):

IBM : **xlc -c new_sleep.c**

INTEL: **icc -c new_sleep.c**

GNU : **gcc -c new_sleep.c**

3 - Compile o programa principal, adicionando o objeto da rotina *sleep*:

IBM : **mpxlf brecv.f new_sleep.o -o brecv ou mpcc brecv.c new_sleep.o -o brecv**

INTEL : **ifort brecv.f new_sleep.o -o brecv -lmpi ou icc brecv.c new_sleep.o -o brecv -lmpi**

MPICH2: **mpif77 brecv.f new_sleep.o -o brecv ou mpicc brecv.c new_sleep.o -o brecv**

4 - Execute o programa iniciando apenas **dois processos**. Execute pelo menos três vezes e anote os tempos de execução.

IBM : **poe ./brecv -procs 2 -hostfile *./arquivo***

INTEL : **mpirun ./brecv -np 2 ./brecv**

MPICH2 : **mpiexec ./brecv -np 2 -f *./arquivo***

arquivo = nome do arquivo de máquinas

Exercício 4

1 - Caminhe para o diretório com o quarto exercício do laboratório.

cd ./lab02/ex4

2 - Edite o programa do exercício anterior:

vi brecv.f **ou** **vi brecv.c** (Outros editores: **pico** ou **nano**)

- Substitua o "blocking receive" por um "non-blocking receive" antes da rotina *new_sleep*;
- Adicione a rotina *MPI_Wait* antes da impressão de mensagem recebida, para se garantir o recebimento.

2 - Compile primeiro a rotina *sleep*, criando apenas o código objeto (opção **-c**):

IBM : **xlc -c new_sleep.c**

INTEL: **icc -c new_sleep.c**

GNU : **gcc -c new_sleep.c**

3 - Compile o programa principal, adicionando o objeto da rotina *sleep*:

IBM : **mpxlf brecv.f new_sleep.o -o brecv** **ou** **mpcc brecv.c new_sleep.o -o brecv**

INTEL : **ifort brecv.f new_sleep.o -o brecv -lmpi** **ou** **icc brecv.c new_sleep.o -o brecv -lmpi**

MPICH2: **mpif77 brecv.f new_sleep.o -o brecv** **ou** **mpicc brecv.c new_sleep.o -o brecv**

4 - Execute o programa iniciando apenas **dois processos**. Execute pelo menos três vezes. Verifique se a execução está correta e se houve alguma melhora no tempo de execução, em relação ao exercício anterior.

IBM : **poe ./brecv -procs 2 -hostfile *./arquivo***

INTEL : **mpirun ./brecv -np 2 ./brecv**

MPICH2 : **mpiexec ./brecv -np 2 -f *./arquivo***

arquivo = nome do arquivo de máquinas

8 - Rotinas de Comunicação Coletiva

- Uma comunicação coletiva envolve todos os processos de um grupo de processos;

- O objetivo deste tipo de comunicação é o de manipular um pedaço **comum** de informação por todos os processos de um grupo;

- As rotinas de comunicação coletiva são montadas utilizando-se as rotinas de comunicação "point-to-point" e somente “blocking”;

- As rotinas de comunicação coletivas estão divididas em três categorias:

  "synchronization"
  "data movement"
  "global computation"

- Envolve comunicação coordenada entre processos de um grupo, identificados pelo parâmetro **"communicator"**;

- Não é necessário rotular as mensagens (utilizar **tags**);

- Todos os processos executam a mesma rotina de comunicação coletiva, que pode funcionar como um “send” ou pode funcionar como um “receive”;

8.1 - "Synchronization"

8.1.1 - Rotina MPI_Barrier

C	**int MPI_Barrier (comm)**
FORTRAN	**CALL MPI_BARRIER (comm, ierr)**

comm Inteiro que determina o **"communicator"**, que por sua vez, determina o grupo de processos;

ierr Inteiro que retorna com o status da execução da rotina.

Aplicações paralelas em ambiente de memória distribuída, as vezes, é necessário que ocorra sincronização implícita ou explicitamente. A rotina **MPI_Barrier**, sincroniza todos os processos de um grupo ("communicator"). Um processo de um grupo que utilize **MPI_Barrier**, para de executar até que todos os processos do mesmo grupo também executem um **MPI_Barrier**.

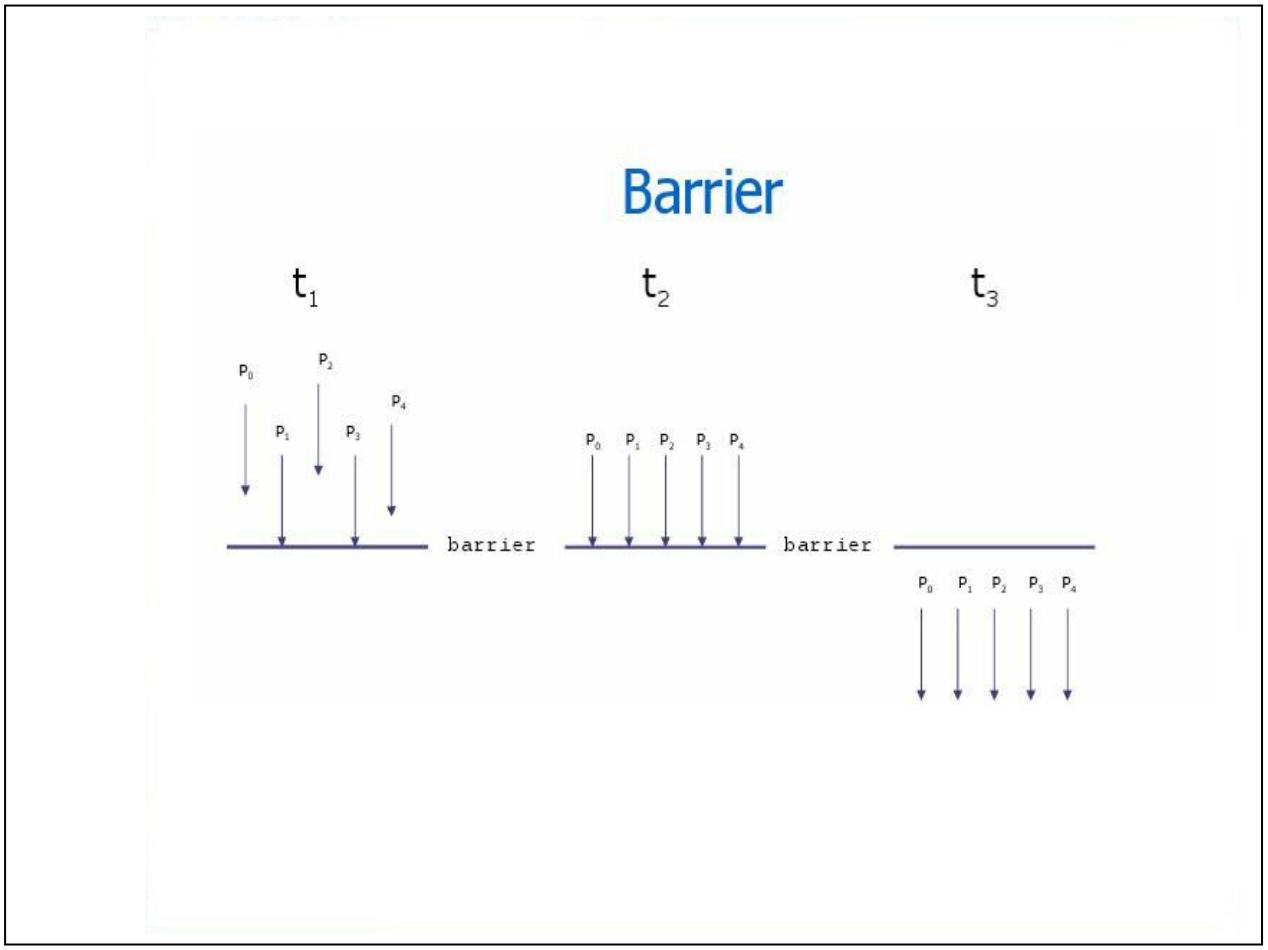

8.2 - "Data Movement"

8.2.1 - Rotina MPI_Broadcast

C	**int MPI_Bcast(*buffer, count, datatype, root, comm)**
FORTRAN	**CALL MPI_BCAST (buffer, count, datatype, root, comm, ierr)**

buffer	Endereço inicial do dado a ser enviado;
count	Variável inteira que indica o número de elementos no **buffer**;
datatype	Constante MPI que identifica o tipo de dado dos elementos no **buffer**;
root	Inteiro com a identificação do processo que irá efetuar um **broadcast**, enviar a mensagem;
comm	Identificação do **communicator**.

Rotina que permite a um processo enviar dados, de imediato, para todos os processos de um grupo. Todos os processos do grupo, deverão executar um **MPI_Bcast**, com o mesmo **comm** e **root**. O processo identificado como **root**, enviará os dados, enquanto que o processo que não possui a identificação **root**, receberá os dados.

```
PROGRAM broad cast
 INCLUDE 'mpif.h'
 INTEGER ierr, myid, nproc, root
 INTEGER status(MPI_STATUS_SIZE)
 REAL A(2)

 CALL MPI INIT(ierr)
 CALL MPI COMM SIZE(MPI COMM WORLD, nproc,ierr)
 CALL MPI_COMM_RANK(MPI_COMM_WORLD, myid, ierr)

 root = 0
 IF( myid .EQ. 0 ) THEN
   a(1) = 2.0
   a(2) = 4.0
 END IF

 CALL MPI_BCAST(a, 2, MPI_REAL, 0, MPI_COMM_WORLD, ierr)

 WRITE(6,*) myid, ': a(1)=', a(1), 'a(2)=', a(2)

 CALL MPI_FINALIZE(ierr)

END
```

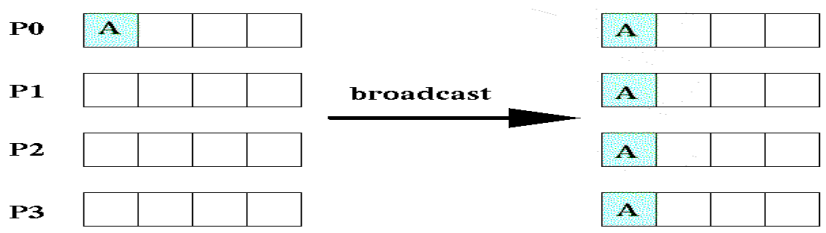

“Scatter” e “Gather”

Se um processo necessita distribuir dados em *n* segmentos iguais, onde o enésimo segmento é enviado para enésimo processo num grupo de *n* processos, utiliza-se a rotina de **SCATTER**. Por outro lado, se um único processo necessita coletar os dados distribuídos em *n* processos de um grupo. Utiliza a rotina de **GATHER**.

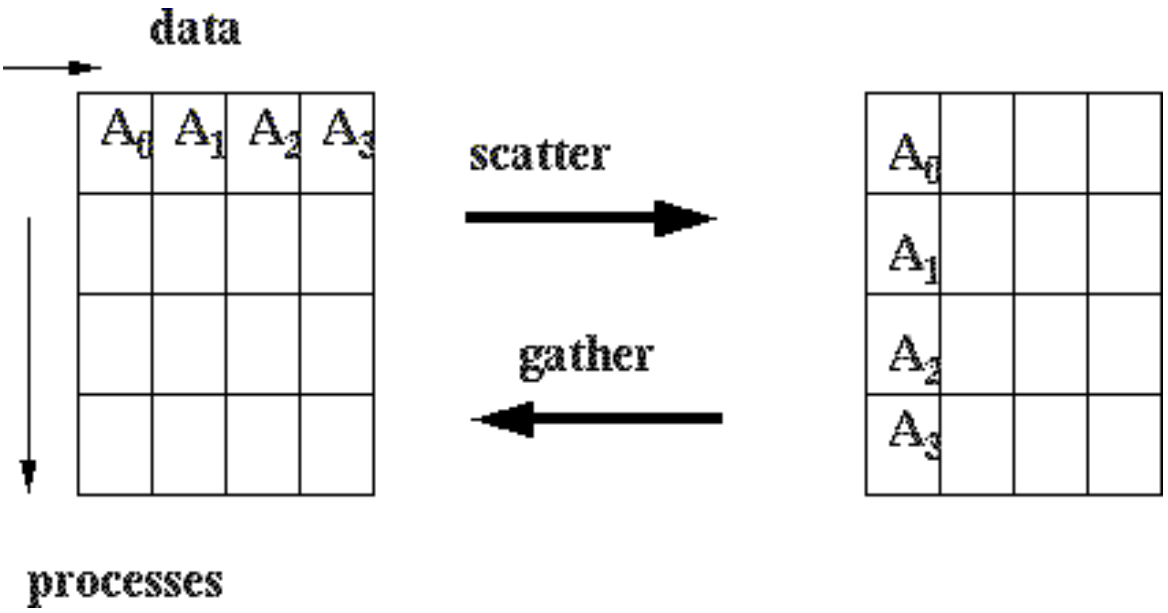

8.2.2 – Rotina MPI_Scatter

C	**int MPI_Scatter(*sbuf, scount, stype, *rbuf, rcount, rtype, root, comm)**
FORTRAN	**CALL MPI_SCATTER(sbuf,scount,stype,rbuf,rcount,rtype,root,comm,ierr)**

sbuf Endereço dos dados que serão distribuídos pelo processo **root**;

scount Número de elementos que serão distribuídos **para cada processo**;

stype Tipo de dado que será distribuído;

rbuf Endereço aonde os dados serão coletados **por cada processo**;

rcount Número de elementos que serão coletados **por cada processo** ;

rtype Tipo de dado que será coletado;

root Identificação do processo que irá distribuir os dados;

comm Identificação do "communicator".

```
real sbuf(MAX), rbuf(100)
.               .          .
.               .          .
.               .          .
call mpi_scatter(sbuf,100,MPI_REAL,rbuf,100,MPI_REAL, root,comm,ierr)
```

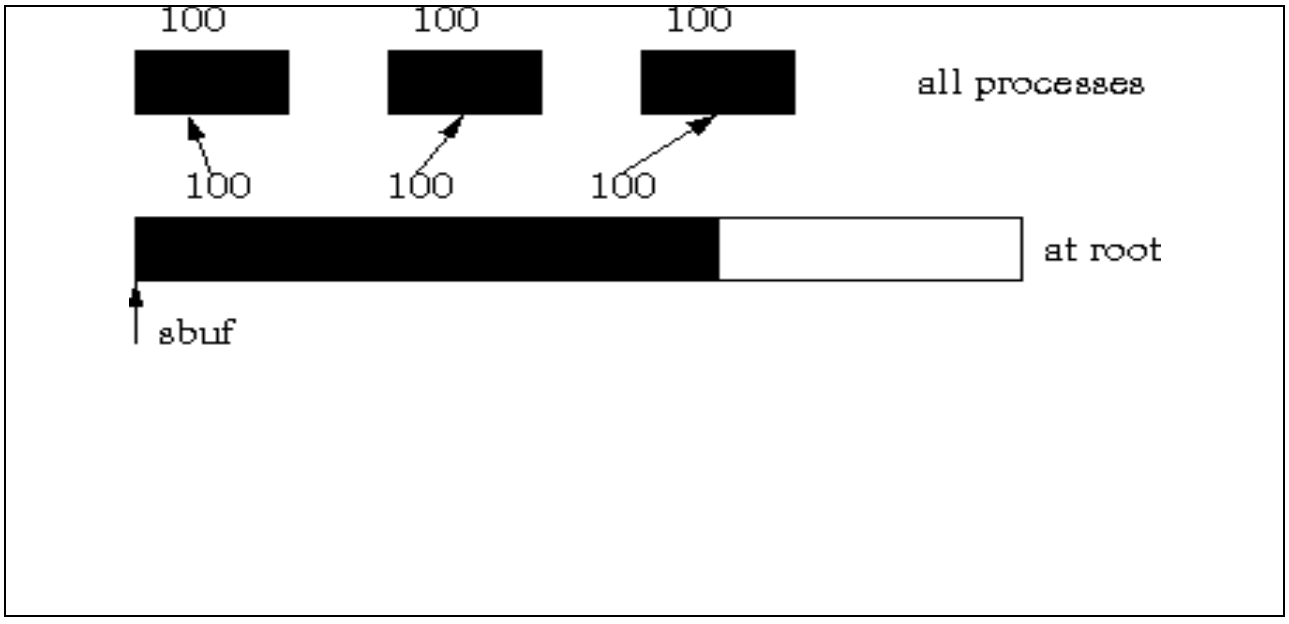

8.2.3 – Rotina MPI_Gather

C	**int MPI_Gather(*sbuf, scount, stype, *rbuf, rcount, rtype, root, comm)**
FORTRAN	**call MPI_GATHER(sbuf, scount, stype, rbuf, rcount, rtype, root, comm, ierr)**

sbuf Endereço inicial dos dados que serão enviados **por cada processo**;

scount Número de elementos que serão enviados **por cada processo**;

stype Tipo de dado que será enviado;

rbuf Endereço aonde os dados serão coletados pelo processo **root**;

rcount Número de elementos que serão coletados;

rtype Tipo de dado coletado;

root Identificação do processo que ira coletar os dados;

comm Identificação do "communicator".

```
real a(100), rbuf(MAX)
.                .           .
.                .           .
.                .           .
call mpi_gather(a,100,MPI_REAL,rbuf,100,MPI_REAL,root, comm, ierr)
```

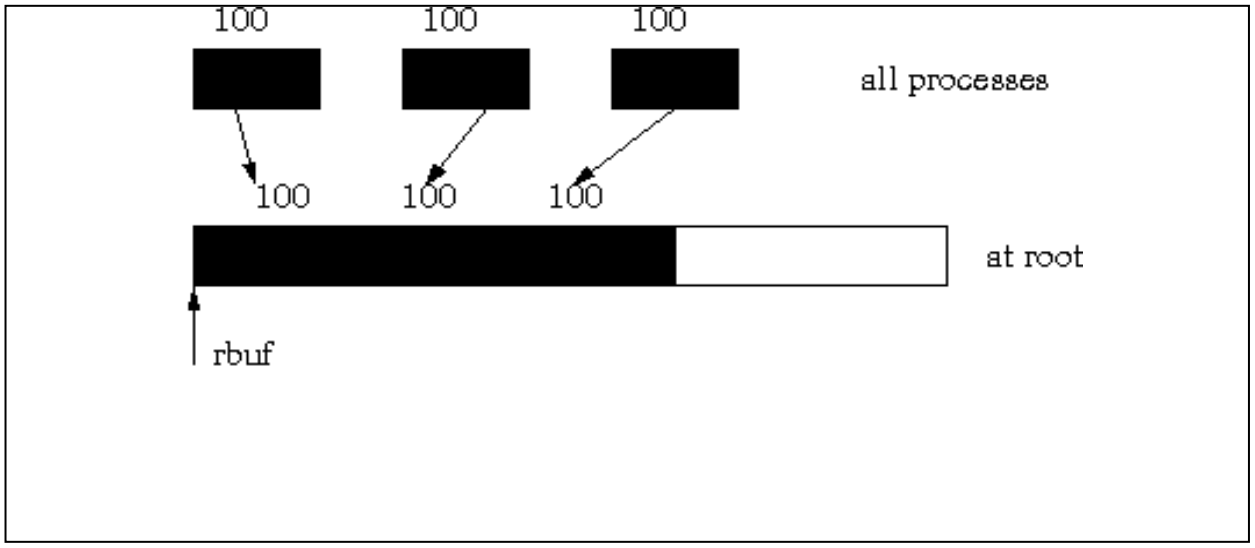

Exemplo

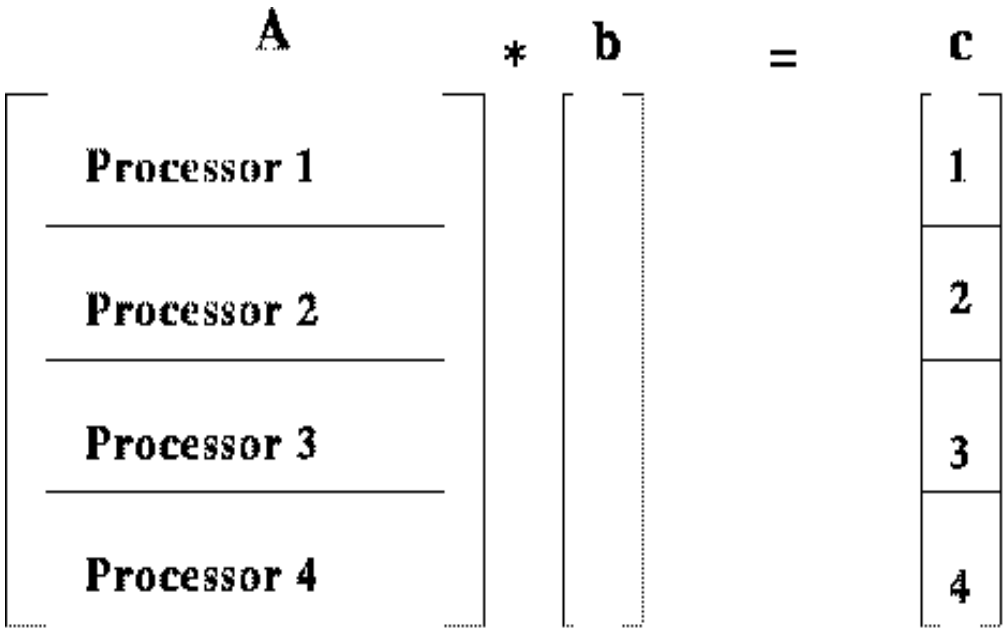

A: Matriz distribuída por linhas;

b: Vetor compartilhado por todos os processos;

c: Vetor atualizado por cada processo, independentemente.

```
 REAL A(100,100), b(100), cpart(25), ctotal(100)
 INTEGER root, me, erro, tp
 DATA root/0/
          …
          (distribuição dos dados) !!!
          …

 DO I=1,25
   cpart(I)=0.
   DO K=1,100
     cpart(I) = cpart(I) + A(I,K)*b(K)
   END DO
 END DO
          …
          …
          …
 CALL MPI_GATHER(cpart,25,MPI_REAL,ctotal,25,MPI_REAL,root,MPI_COMM_WORLD,ierr)
 CALL MPI_Finalize(erro);
          …
          …
          …
END
```

OBS: Exemplo completo no LABORATÓRIO3 na pasta exemplo:

lab03/exemplo/multiplicacao_matriz_vetor.f
lab03/exemplo/multiplicacao_matriz_vetor.c

8.2.4 – Rotina MPI_Allgather

C	**int MPI_Allgather(*sbuf, scount, stype, *rbuf, rcount, rtype, comm)**
FORTRAN	**CALL MPI_ALLGATHER(sbuf,scount,stype,rbuf,rcount,rtype,comm,ierr)**

sbuf Endereço inicial dos dados que serão enviados **por todos os processos**;

scount Número de elementos que serão enviados **por todos os processos**;

stype Tipo de dado que será distribuído;

rbuf Endereço aonde os dado serão coletados por **todos os processos**;

rcount Número de elementos que serão coletados **por todos os processos**;

rtype Tipo de dado coletado;

comm Identificação do "communicator".

Essa rotina ao ser executada faz com que todos os processos enviem dados e coletem dados de cada processo da aplicação. Seria similar a **cada processo** efetuar um **"brodcast".**

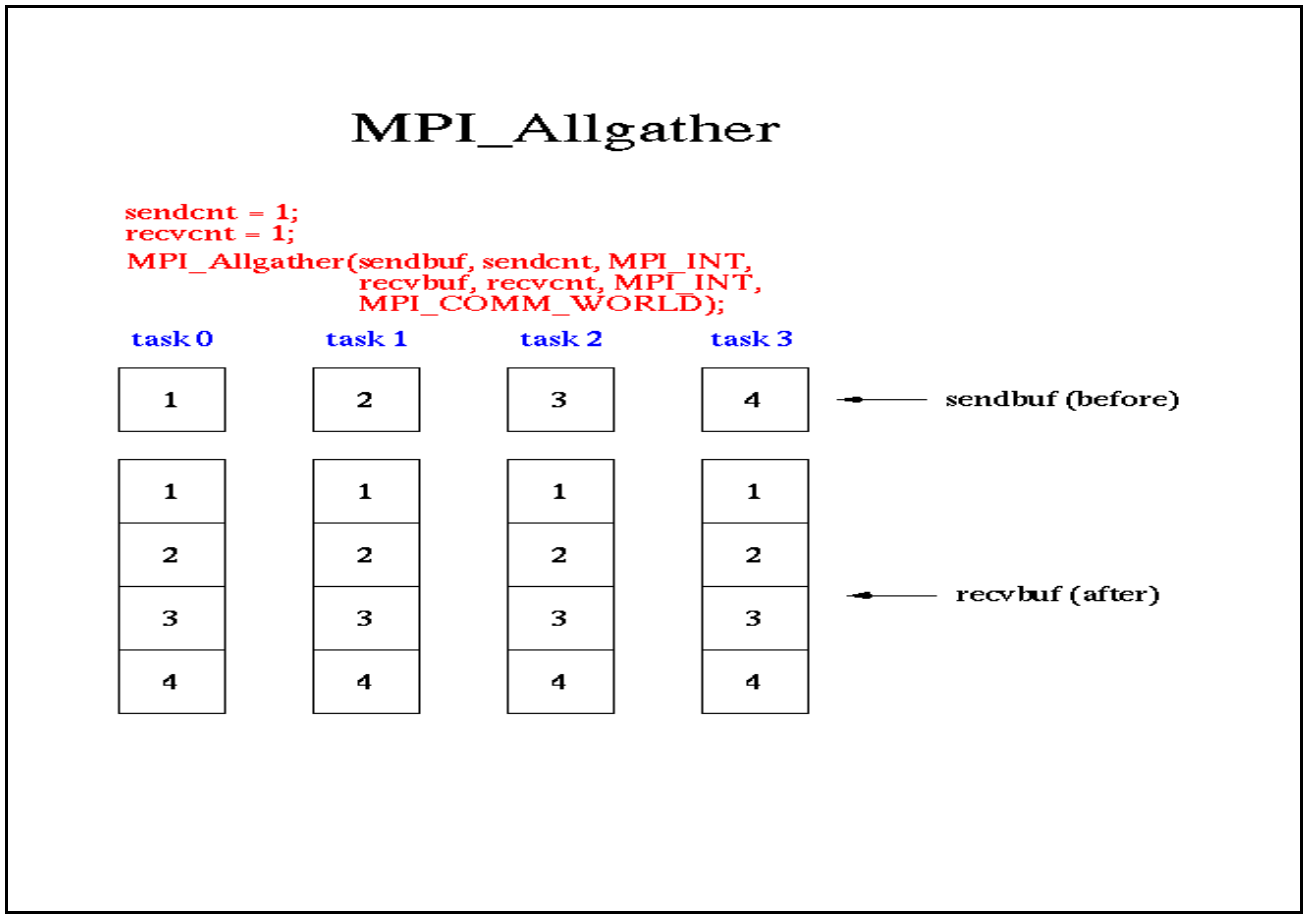

8.2.5 – Rotina MPI_Alltoall

C	**int MPI_Alltoall(*sbuf, scount, stype, *rbuf, rcount, rtype, comm)**
FORTRAN	**CALL MPI_ALLTOALL(sbuf,scount,stype,rbuf,rcount,rtype,comm,ierr)**

sbuf Endereço inicial dos dados que serão distribuídos por **todos os processos**;

scount Número de elementos que serão distribuídos **por todos os processos**;

stype Tipo de dado que será distribuído;

rbuf Endereço aonde o dados serão coletados **por todos os processos**;

rcount Número de elementos que serão coletados **por todos os processos**;

rtype Tipo de dado coletado;

comm Identificação do "communicator".

Esta rotina ao ser executada faz com que cada processo distribua seus dados para todos os outros processos da aplicação. Seria similar a **cada processo** efetuar um **"scatter"**.

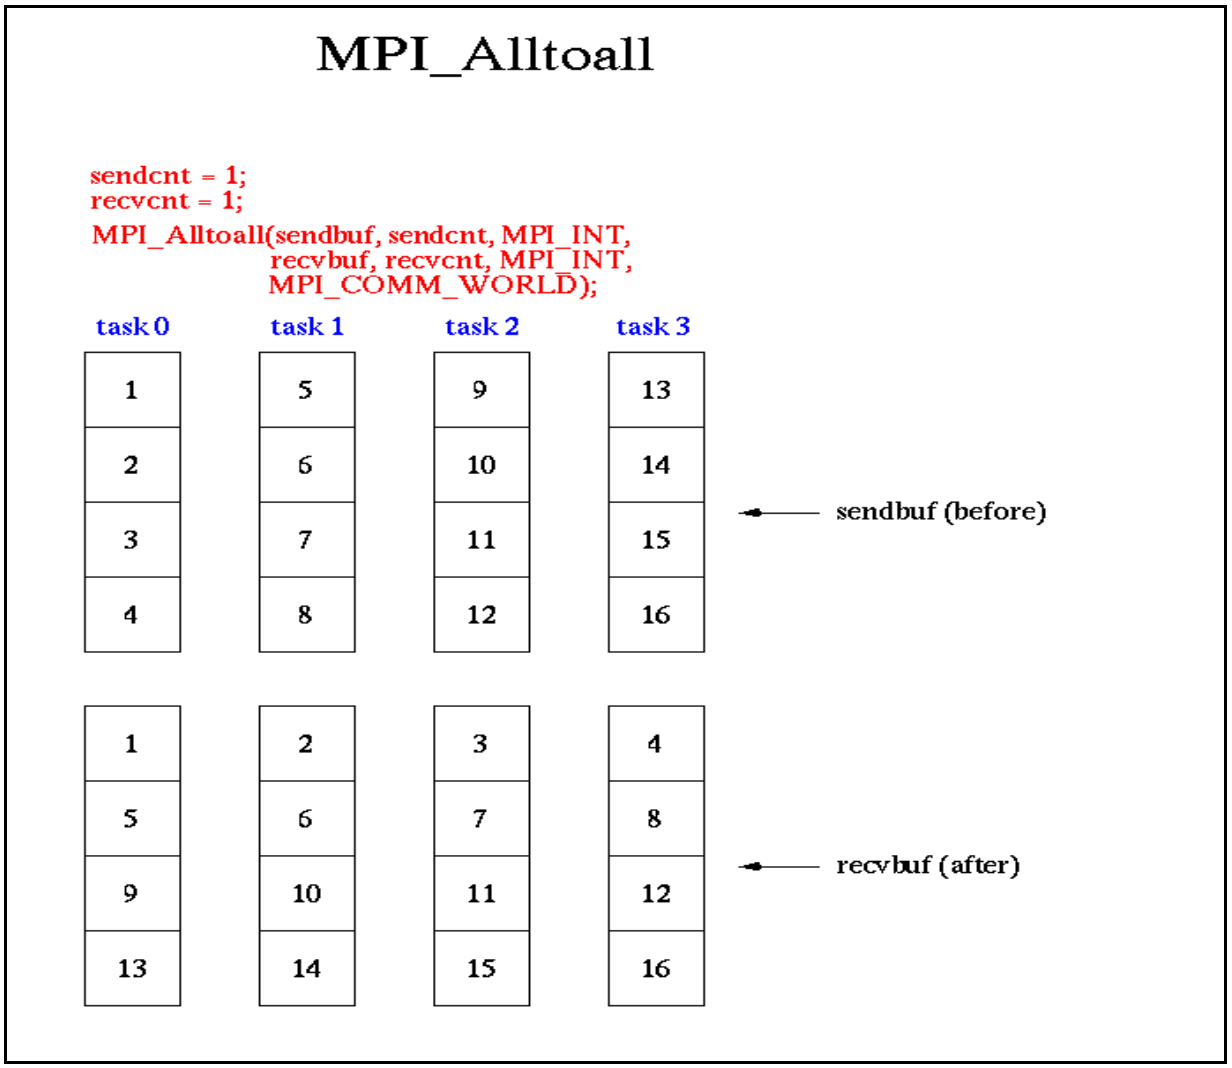

8.3 - Computação Global

Uma das ações mais úteis em operações coletivas são as operações globais de redução ou combinação de operações. O resultado parcial de um processo, em um grupo, é combinado e retornado para um específico processo utilizando-se algum **tipo de função de operação.**

8.3.1 – Rotina MPI_Reduce

C	**int MPI_Reduce(*sbuf, *rbuf, count, stype, op, root, comm)**
FORTRAN	**call MPI_REDUCE(sbuf,rbuf,count,stype,op,root,comm,ierr)**

sbuf Endereço do dado que fará parte de uma operação de redução ("send buffer");

rbuf Endereço da variável que coletará o resultado da redução ("receive buffer");

count Número de elementos que farão parte da redução;

stype Tipo dos dados na operação de redução;

op Tipo da operação de redução;

root Identificação do processo que irá receber o resultado da operação de redução;

comm Identificação do "communicator".

Tabela com Funções Pré-definidas de Operações de Redução

FUNÇÃO	RESULTADO	C	FORTRAN
MPI_MAX	**valor máximo**	**integer,float**	**integer,real,complex**
MPI_MIN	**valor mínimo**	**integer,float**	**integer,real,complex**
MPI_SUM	**somatório**	**integer,float**	**integer,real,complex**
MPI_PROD	**produto**	**integer,float**	**integer,real,complex**

MPI_Reduce

```
count = 1;
dest  = 1;                          result will be placed in task 1
MPI_Reduce(sendbuf, recvbuf, count, MPI_INT, MPI_SUM,
           dest, MPI_COMM_WORLD);
```

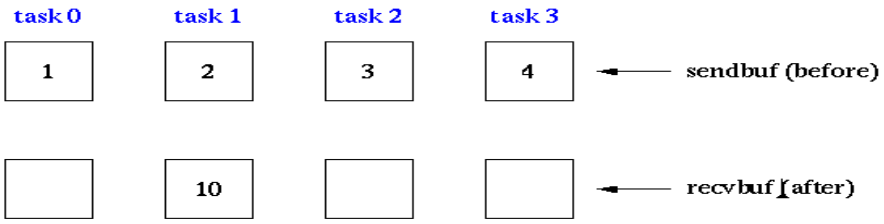

C

```
#include   <stdio.h>
#include   <mpi.h>
void main(int argc, char *argv[])
{
   int rank;
   int source,result,root;

/* run on 10 processors */

MPI Init(&argc, &argv);
MPI Comm rank(MPI COMM WORLD,&rank);

root=7;
source=rank+1;
MPI_Barrier(MPI_COMM_WORLD);

MPI_Reduce(&source,&result,1,MPI_INT,
           MPI_PROD,root,MPI_COMM_WORLD);

if(rank==root)
 printf("P:%d MPI_PROD result is %d
\n",rank,result);

MPI Finalize();
}
```

Fortran

```
PROGRAM product
 INCLUDE 'mpif.h'
 INTEGER err, rank, size
 INTEGER source,result,root

C  run on 10 processors

 CALL MPI INIT(err)
 CALL MPI COMM RANK(MPI COMM WORLD, rank, err)
 CALL MPI_COMM_SIZE(MPI_COMM_WORLD, size, err)

 root=7
 source=rank+1
 call MPI BARRIER(MPI COMM WORLD,err)

 call MPI_REDUCE(source,result,1,MPI_INT, &
      MPI_PROD,root,MPI_COMM_WORLD,err)

 if(rank.eq.root) then
  print *,'P:',rank,' MPI PROD result is',result
 end if

 CALL MPI_FINALIZE(err)
END
```

LABORATÓRIO 3 - Comunicação Coletiva

Exercício 1

1 - Caminhe para o diretório com o primeiro exercício do laboratório. Edite o programa e altere o que for solicitado:

cd ./lab03/ex1
vi collective.f ou vi collective.c (Outros editores: **pico** ou **nano**)

- O processo mestre solicita a entrada de um número, que será a semente para o cálculo de um número randômico, esse número será **enviado para todos os processos**.

  1ª Rotina: Adicione ao programa, no lugar da "seta", a rotina MPI que envia dados para todos os processos;

- Cada processo calculará um número randômico, baseado no número de entrada informado. O processo com o maior número de identificação **receberá o somatório dos números randômicos** e calculará o valor médio de todos os números randômicos calculados.

  2ª Rotina: Adicione ao programa, no lugar da "seta", a rotina MPI que efetua uma operação global de redução;

- Cada processo irá calcular, novamente, mais 4 novos números randômicos. Um processo **receberá todos os números randômicos**, irá calcular o valor máximo e o desvio padrão, e os resultados **serão distribuídos para todos os processos**. Existem dois métodos par efetuar essas tarefas, utilizando rotinas de comunicação coletiva diferentes.

  1º Método - 3ª Rotina: Adicione ao programa, no lugar das "setas", a rotina MPI que coleta os dados de outros processo;

  4ª Rotina: Adicione ao programa, no lugar das "setas", a rotina MPI que envia os dados para todos os processos;

  2º Método - 5ª Rotina: Adicione ao programa, no lugar das "setas", a rotina MPI que coleta e envia, simultaneamente, os dados dos processo;

2 - Compile o programa:

IBM : **mpxlf collective.f -o cole ou mpcc collective.c -o cole**

INTEL : **ifort collective.f -o cole -lmpi ou icc collective.c -o cole -lmpi**

MPICH2 : **mpif77 collective.f -o cole ou mpicc collective.c -o cole**

3 - Execute o programa:

IBM : **poe ./cole -procs *n* -hostfile *./arquivo***

INTEL : **ulimit –v unlimited**

mpirun -np *n* ./cole

MPICH2 : **mpiexec ./cole -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

Exercício 2

1 - Caminhe para o diretório com o segundo exercício do laboratório.

cd ./lab03/ex2

A idéia do programa é demonstrar a execução da rotina **MPI_SCATTER.**

2 - Edite o programa e adicione os parâmetros da rotina, para que ela funcione adequadamente.

vi sactter.f **ou** **vi scatter.c** (Outros editores: **pico** ou **nano**)

3 - Compile o programa:

IBM : **mpxlf scatter.f -o sca** **ou** **mpcc scatter.c -o sca**

INTEL : **ifort scatter.f -o sca -lmpi** **ou** **icc scatter.c -o sca -lmpi**

MPICH2 : **mpif77 scatter.f -o sca** **ou** **mpicc scatter.c -o sca**

4 - Execute o programa:

IBM : **poe ./sca -procs *n* -hostfile ./*arquivo***

INTEL : **mpirun -np *n* ./sca**

MPICH2 : **mpiexec ./sca -np *n* -f ./*arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

Exercício 3

1 - Caminhe para o diretório com o primeiro exercício do laboratório.

cd ./lab03/ex3

Este programa calcula o maior número primo dos números primos calculados, até um limite determinado pelo programador (O valor da variável LIMIT). A idéia e demonstrar a utilização, apenas da rotina de operação de redução, **MPI_REDUCE.**

2 - Edite o programa e adicione os parâmetros da rotina, para que ela funcione adequadamente.

vi mpi_prime.f ou vi mpi_prime.c (Outros editores: **pico** ou **nano**)

3 - Compile o programa:

IBM : **mpxlf mpi_prime.f -o primo ou mpcc mpi_prime.c -o primo**

INTEL : **ifort mpi_prime.f -o primo -lmpi ou icc mpi_prime.c -o primo -lmpi**

MPICH2 : **mpif77 mpi_prime.f -o primo ou mpicc mpi_prime.c -o primo**

4 - Execute o programa:

IBM : **poe ./primo -procs *n* -hostfile *./arquivo***

INTEL : **mpirun -np *n* ./primo**

MPICH2 : **mpiexec ./primo -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

Exercício 4

1 - Caminhe para o diretório com o quarto exercício do laboratório.

cd ./lab03/ex4

Este exercício possui programas que calculam o valor de pi, com o uso de um algoritmo especial:

1.1 - Na primeira solução, e utilizada as rotinas de **send** e **receive** para que os processos calculem uma parte do valor de pi. O valor de pi é calculado por uma subrotina externa (**dboard.f**), que deve ser compilada junto com o programa principal. Apenas analise a paralelização do programa com essas rotinas e verifique a execução

- Compile o programa:

IBM : **mpxlf pi_paralelo_v1.f dboard.f -o piv1 ou mpcc pi_paralelo_v1.c dboard.c -o piv1**

INTEL : **ifort pi_paralelo_v1.f dboard.f -o piv1 -lmpi ou icc pi_paralelo_v1.c dboard.c -o piv1 -lmpi**

MPICH2: **mpif77 pi_paralelo_v1.f dboard.f -o piv1 ou mpicc pi_paralelo_v1.c dboard.c -o piv1**

- Execute o programa:

IBM : **poe ./piv1 -procs *n* -hostfile *./arquivo***

INTEL : **mpirun ./piv1 -np *n* -machinefile *./arquivo***

MPICH2 : **mpiexec ./piv1 -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

1.2 - A segunda solução, é mais eficiente pois utiliza uma rotina MPI de comunicação coletiva. A lógica de paralelização está pronta, apenas codifique as rotinas MPI necessarias.

- Edite o programa e codifique o que for necessário para executar com MPI:

vi pi_paralelo_v2.f ou vi pi_paralelo_v2.c (Outros editores: **pico** ou **nano**)

- Compile o programa:

IBM : **mpxlf pi_paralelo_v2.f dboard.f -o piv2 ou mpcc pi_paralelo_v2.c dboard.c -o piv2**

INTEL : **ifort pi_paralelo_v2.f dboard.f -o piv2 -lmpi ou icc pi_paralelo_v2.c dboard.c -o piv2 -lmpi**

MPICH2: **mpif77 pi_paralelo_v2.f dboard.f -o piv2 ou mpicc pi_paralelo_v2.c dboard.c -o piv2**

- Execute o programa:

IBM : **poe ./piv2 -procs *n* -hostfile *./arquivo***

INTEL : **mpirun -np *n* ./piv2**

MPICH2 : **mpiexec ./piv2 -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

9 - Grupos e “Communicators”

Grupo

- Grupo é um conjunto ordenado de processos. Cada processo em um grupo pode possuir um novo e único número de identificação;
- O MPI suporta o processamento de grupos, permitindo:
    1. Organizar processos em grupos, de acordo com a natureza da aplicação;
    2. Permitir operações de Comunicação Coletiva entre alguns processos;
- Um processo pode pertencer a mais de um grupo;

“Communicator”

- Um grupo utiliza um “communicator” específico, que descreve o universo de comunicação entre os processos;
- Em têrmos de programação, grupo e communicator são equivalentes;
- Em MPI, grupo e communicator são objetos dinâmico que podem ser criados e destruídos durante a execução de um programa.

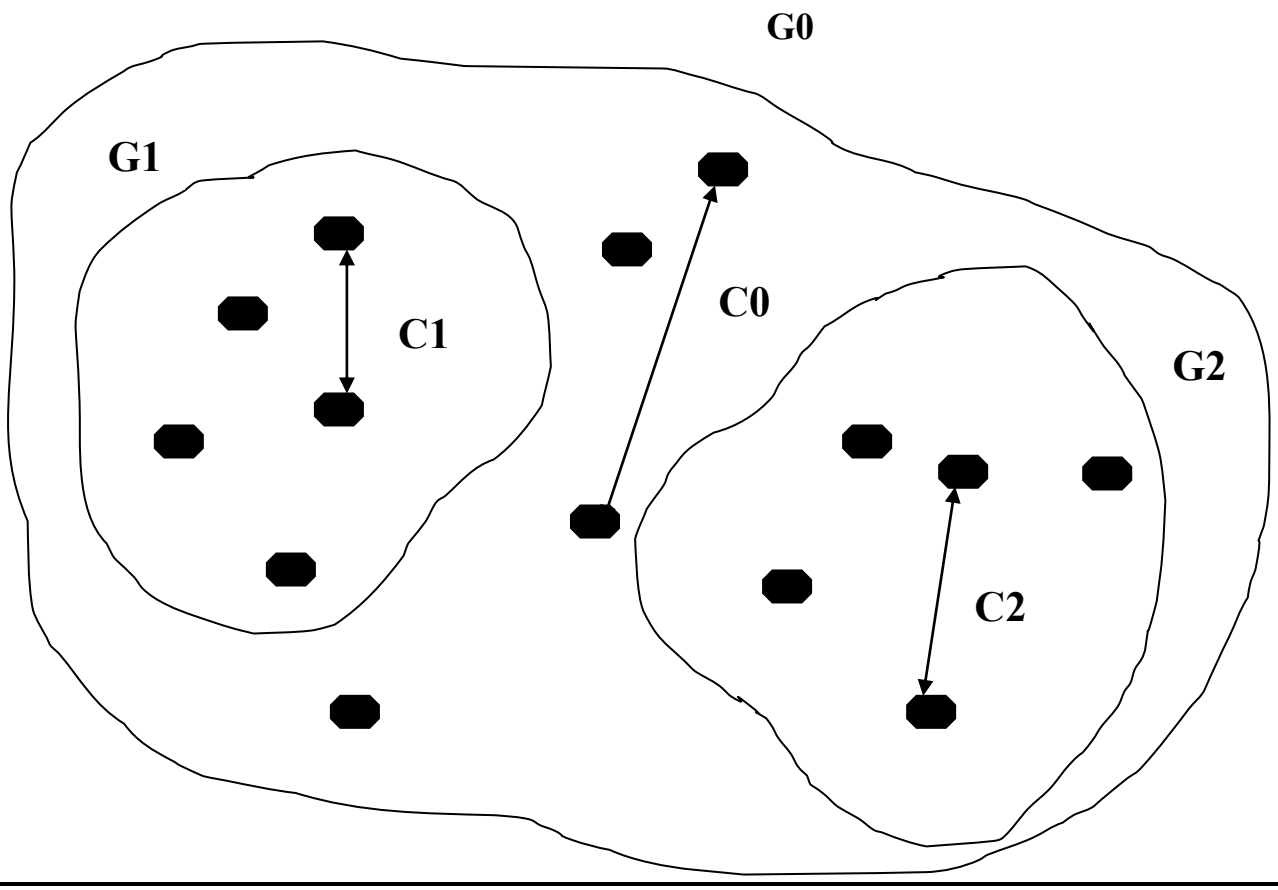

9.1 - Identifica um Grupo - Rotina MPI_Comm Group

C	**int MPI_Comm_group(comm , *group)**
FORTRAN	**CALL MPI_COMM_GROUP (comm, group, ierr)**

Identifica o grupo que está associado a um determinado "communicator". É necessário identificar o grupo para poder criar novos grupos.

comm "Communicator"

group Variável inteira, "transparente", de retorno, com a identificação do grupo.

ierr Status de execução da rotina.

9.2 - Cria um Grupo por Inclusão - Rotina MPI_Group_incl

C	**int MPI_Group_incl (group, n, *ranks, *newgroup)**
FORTRAN	**CALL MPI_GROUP_INCL (group, n, ranks, newgroup, ierr)**

Cria um novo grupo a partir de um grupo existente, com a **inclusão de processos** identificados.

group Variável inteira, ***transparente***, que identifica o grupo que já existe;

n Número de processos que serão incluídos no novo grupo (Também indica o tamanho do conjunto de ***ranks*);**

ranks Vetor com a identificação dos processos do grupo existente, que serão **incluídos**;

newgroup Variável inteira, ***transparente***, que irá armazenar a identificação do novo grupo.

ierr Status de execução da rotina.

9.3 - Cria um Grupo por Exclusão - Rotina MPI_Group_excl

C	**int MPI_Group_excl (group, n, *ranks, *newgroup)**
FORTRAN	**call MPI_GROUP_EXCL (group, n, ranks, newgroup, ierr)**

Cria um novo grupo a partir de um grupo existente, com a **exclusão de processos** que são identificados.

group Variável inteira, ***transparente***, que identifica o grupo que já existe.

n Número de processos que serão excluídos do novo grupo (Também indica o tamanho do conjunto ***ranks);***

ranks Vetor com a identificação dos processos no grupo existente, que serão **excluídos**. Os processos que não forem identificados, farão parte do novo grupo;

newgroup Variável inteira, ***transparente***, que irá armazenar a identificação do novo grupo.

ierr Status de execução da rotina.

9.4 - Identifica Processo no Grupo - Rotina MPI_Group_rank

C	**int MPI_Group_rank(group, *rank)**
FORTRAN	**CALL MPI_GROUP_RANK(group, rank, ierr)**

Rotina que identifica um processo dentro do novo grupo.

group Variável inteira, "transparente", com a identificação do grupo;

rank Variável inteira de retorno com a identificação do processo no grupo. Número contínuo de 0 a n-1;

ierr Status de execução da rotina.

9.5 - Cria um "Communicator" - Rotina MPI_Comm_create

C	**int MPI_Comm_create (comm, group, *newcomm)**
FORTRAN	**CALL MPI_COMM_CREATE (comm, group, newcomm, ierr)**

Cria um novo "communicator", a partir do "communicator" existente, para o novo grupo.

comm "Communicator" no qual pertenciam os processos.

group Variável inteira, ***transparente***, que identifica o novo grupo.

newcomm Variável inteira, ***transparente***, que irá armazenar a identificação do novo "communicator".

ierr Status de execução da rotina.

9.6 - Apagar Grupos - Rotina MPI_Group_free

C	**int MPI_Group_free (group)**
FORTRAN	**CALL MPI_GROUP_FREE (group, ierr)**

Apaga, somente, a definição de um grupo.

group Variável inteira, ***transparente***, que identifica o grupo que será apagado a definição.

ierr Status de execução da rotina.

9.7 - Apagar "Communicators" - Rotina MPI_Comm_free

C	**int MPI_Comm_free (*comm)**
FORTRAN	**CALL MPI_COMM_FREE (comm, ierr)**

Apaga a definição de um "communicator".

comm Variável inteira, ***transparente***, que identifica o "communicator" que será apagado a definição.

ierr Status de execução da rotina.

Exemplo de Uso de Grupos e "Communicators"

```
PROGRAM mainprog
   IMPLICIT NONE

   INCLUDE "mpif.h"

   INTEGER                 :: me
   INTEGER                 :: ranks = 0
   INTEGER                 :: send_buf=1, send_buf2=1, recv_buf=0, recv_buf2=0
   INTEGER                 :: count=1, count2=1
   INTEGER                 :: COMMSLAVE, MPI_GROUP_WORLD
   INTEGER                 :: GRPREM,  rstat    ! Status variable

   CALL MPI_Init(rstat)
   CALL MPI_Comm_rank(MPI_COMM_WORLD, me, rstat)

! Identificar o grupo principal

   CALL MPI_Comm_group(MPI_COMM_WORLD, MPI_GROUP_WORLD, rstat)

! Criar um novo grupo a partir da exclusão de processos

   CALL MPI_Group_excl(MPI_GROUP_WORLD, 1, ranks, GRPREM, rstat)

! Criar um novo "communicator" para o novo grupo

   CALL MPI_Comm_create(MPI_COMM_WORLD, grprem, COMMSLAVE, rstat)

   IF (me /= 0) THEN
      CALL MPI_Reduce(send_buf, recv_buf, count, MPI_INT, &
                      MPI_SUM, 1, COMMSLAVE, rstat)
   END IF

   CALL MPI_Reduce(send_buf2, recv_buf2, count2, MPI_INT, &
                   MPI_SUM, 0, MPI_COMM_WORLD, rstat)

   print *,"Processo",me,"Grupo=",recv_buf,"Geral=",recv_buf2

   IF (commslave /= MPI_COMM_NULL) THEN
      CALL MPI_Comm_free(COMMSLAVE, rstat)
   END IF

   CALL MPI_Group_free(MPI_GROUP_WORLD, rstat)
   CALL MPI_Group_free(GRPREM, rstat)

   CALL MPI_Finalize(rstat)
END PROGRAM mainprog
```

mpirun -np 6 ./a.out

```
 Processo           0 Grupo=           0 Geral=           6
 Processo           1 Grupo=           5 Geral=           0
 Processo           3 Grupo=           0 Geral=           0
 Processo           4 Grupo=           0 Geral=           0
 Processo           5 Grupo=           0 Geral=           0
 Processo           2 Grupo=           0 Geral=           0
```

LABORATÓRIO 4 - Grupo e "|Communicator"

Exercício 1

1 - Caminhe para o diretório com o primeiro exercício do laboratório:

cd ./lab04/ex1

Neste exercício, serão criados dois grupos identificados como: processos ímpares e processos pares. Cada grupo executará uma operação de redução.

2 - Edite o programa e **adicione, no lugar das "setas", a rotina MPI adequada para esta operação**;

vi create.f ou vi create.c (Outros editores: **pico** ou **nano**)

3 - Compile o programa:

IBM : **mpxlf create.f -o grupo ou mpcc create.c -o grupo**

INTEL : **ifort create.f -o grupo -lmpi ou icc create.c -o grupo -lmpi**

MPICH2: **mpif77 create.f -o grupo ou mpicc create.c -o grupo**

4 - Execute o programa:

IBM : **poe ./grupo -procs *n* -hostfile *./arquivo***

INTEL : **ulimit –v unlimited**

mpirun -np *n* ./grupo

MPICH2 : **mpiexec ./grupo -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

Exercício 2

1 - Caminhe para o diretório com o primeiro exercício do laboratório:

cd ./lab04/ex2

Neste exercício serão criados dois grupos utilizando a rotina de inclusão em grupo, que será executada duas vezes para dois vetores de identificação de processos. No final da execução do programa.

2 - Edite o programa e **adicione, no lugar das "setas", a rotina MPI adequada para esta operação**;

vi mpi_group.f ou vi mpi_group.c (Outros editores: **pico** ou **nano**)

3 - Compile o programa:

IBM : **mpxlf mpi_group.f -o grp ou mpcc mpi_group.c -o grp**

INTEL : **ifort mpi_group.f -o grp -lmpi ou icc mpi_group.c -o grp -lmpi**

MPICH2: **mpif77 mpi_group.f -o grp ou mpicc mpi_group.c -o grp**

4 - Execute o programa:

IBM : **poe ./grp -procs *n* -hostfile *./arquivo***

INTEL : **mpirun -np *n* ./grp**

MPICH2 : **mpiexec ./grp -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

LABORATÓRIO 5 – Problemas de Execução

Exercício 1

1 - Caminhe para o diretório com o primeiro exercício do laboratório:

cd ./lab05/ex1

O programa possui um problema que trava a execução.

2 - Compile o programa:

IBM : **mpxlf mpi_bug1.f -o bug1** **ou** **mpcc mpi_bug1.c -o bug1**

INTEL : **ifort mpi_bug1.f -o bug1 -lmpi** **ou** **icc mpi_bug1.c -o bug1 -lmpi**

MPICH2: **mpif77 mpi_bug1.f -o bug1** **ou** **mpicc mpi_bug1.c -o bug1**

3 - Execute o programa, iniciando apenas 2 processos:

IBM : **poe ./bug1 -procs 2 -hostfile *./arquivo***

INTEL : **mpirun -np 2 ./bug1**

MPICH2 : **mpiexec ./bug1 -np** *2* **-f *./arquivo***

arquivo = nome do arquivo de máquinas

4 - Edite o programa e tente corrigir o problema.

vi mpi_bug1.f **ou** **vi mpi_bug1.c** (Outros editores: **pico** ou **nano**)

5 - Compile e execute novamente.

Exercício 2

1 - Caminhe para o diretório com o primeiro exercício do laboratório:

cd ./lab05/ex2

Os dados recebidos e impressos por um processo, são diferentes dos dados enviados. Aonde está o problema?

2 - Compile o programa:

IBM : **mpxlf mpi_bug2.f -o bug2** **ou** **mpcc mpi_bug2.c -o bug2**

INTEL : **ifort mpi_bug2.f -o bug2 -lmpi** **ou** **icc mpi_bug2.c -o bug2 -lmpi**

MPICH2: **mpif77 mpi_bug2.f -o bug2** **ou** **mpicc mpi_bug2.c -o bug2**

3 - Execute o programa, iniciando apenas 2 processos:

IBM : **poe ./bug2 -procs 2 -hostfile *./arquivo***

INTEL : **mpirun -np 2 ./bug2**

MPICH2 : **mpiexec ./bug2 -np** *2* **-f *./arquivo***

arquivo = nome do arquivo de máquinas

4 - Edite o programa e tente corrigir o problema.

vi mpi_bug2.f **ou** **vi mpi_bug2.c** (Outros editores: **pico** ou **nano**)

5 - Compile e execute novamente.

Exercício 3

1 - Caminhe para o diretório com o primeiro exercício do laboratório:

cd ./lab05/ex3

A execução e cancelada por erros de violação de memória. Aonde está o problema?

2 - Compile o programa:

IBM : **mpxlf mpi_bug3.f -o bug3** **ou** **mpcc mpi_bug3.c -o bug3**

INTEL : **ifort mpi_bug3.f -o bug3 -lmpi** **ou** **icc mpi_bug3.c -o bug3 -lmpi**

MPICH2: **mpif77 mpi_bug3.f -o bug3** **ou** **mpicc mpi_bug3.c -o bug3**

3 - Execute o programa:

IBM : **poe ./bug3 -procs *n* -hostfile *./arquivo***

INTEL : **mpirun -np *n* ./bug3**

MPICH2 : **mpiexec ./bug3 -np *n* -f *./arquivo***

n = número de processos
arquivo = nome do arquivo de máquinas

4 - Edite o programa e tente corrigir o problema.

vi mpi_bug3.f **ou** **vi mpi_bug3.c** (Outros editores: **pico** ou **nano**)

5 - Compile e execute novamente.

10 - Referências

1 - **Message Passing Interface (MPI)**
MHPCC - Maui High Performance Computing Center
Blaise Barney - August 29, 1996

2 - **SP Parallel Programming Workshop - Message Passing Overview**
MHPCC - Maui High Performance Computing Center
Blaise Barney - 03 Julho 1996

3 - **Programming Languages and Tools: MPI**
CTC - Cornell Theory Center
April, 1996

4 - **MPI: A Message-Passing Interface Standard**
University of Tennesse, Knoxville, Tennesse
May 5, 1994

5 - **MPI: The Complete Reference**
The MIT Press - Cambridge, Massachusetts
Marc Snir, Steve Otto, Steven Huss-Lederman,
David Walker, Jack Dongarra
1996

6 - **Democritos/ICTP course in "Tools for computational physics"**
Democritos/INFM + SISSA
Stefano Cozzini cozzini@democritos.it
Fevereiro/2005

7 - **Introduction to Parallel Computing**
Lawrance Livermore National Laboratory – LLNL
California – USA – 22 Junho 2007
Blaise Barney